

Pytania egzamin 2021/2022 i 2022/2023

31 maja 2025

1. Model systemu rzeczywistego:

- (a) Jest wykorzystywany tylko w obszarze nauki i techniki
- (b) Jest przybliżonym opisem systemu wynikającym z poczynionych założeń upraszczających
- (c) Może mieć moc wyjaśniającą naturę modelowanego systemu
- (d) Zawsze jest wyrażany w języku matematyki w postaci stosownego równania

Wyjaśnienie:

Nie tylko w obszarze nauki i techniki, można zamodelować większość otaczającego nas świata. Nie zawsze jest wyrażany w postaci stosownego równania – nie trzeba go wyrażać za pomocą matematyki. Każdy model jest tylko pewnym przybliżeniem opisu systemu, po to tworzymy model aby wyjaśnić jakiś system.

2. Podczas procedury identyfikacji systemu

- (a) Należy pobudzać sygnałem wejściowym o dostatecznie bogatym spektrum częstotliwościowym
- (b) Rzad przyjętej struktury modelu nie ma wpływu na jakość identyfikacji
- (c) Etap weryfikacji modelu powinien być realizowany w oparciu o dane użyte do estymacji parametrów
- (d) Etap weryfikacji modelu powinien być realizowany w oparciu o inne dane niż te użyte podczas etapu estymacji parametrów

3. Identyfikacja systemu dynamicznego:

- (a) Polega na dopasowaniu modelu do danych eksperymentalnych
- (b) Musi być przeprowadzana w zamkniętym układzie regulacji
- (c) Wymaga znajomości praw fizyki determinujących odpowiedź systemu
- (d) Wymaga znajomości lub pomiaru sygnału wejściowego u i wyjściowego y identyfikowanego systemu
- (e) jest tożsama z analitycznym modelowaniem systemu dynamicznego

Wyjaśnienie:

Identyfikacja to tworzenie modelu matematycznego systemu w oparciu o dostępną wiedzę wstępną i na podstawie zarejestrowanych danych eksperymentalnych z wejścia i wyjścia, na podstawie tego dopasowujemy stworzony model do danych eksperymentalnych.

4. Model eksperymentalny:

- (a) W warunkach praktycznych zawsze jest obciążony niepewnością modelowania
- (b) Nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori
- (c) Nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu jest znana a priori
- (d) Nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori
- (e) Ma zwykle podobną moc wyjaśniającą jak model analityczny
- (f) Nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu nie jest znana a priori

Wyjaśnienie:

W praktyce taki model zawsze będzie miał jakąś niepewność modelowania – nie ma idealnych przypadków. Model typu GREY-BOX to model w którym znana jest struktura modelu, a my staramy się zidentyfikować jego parametry modelu. W BLACK-BOX nie ma ani tego ani tego.

5. Procedura identyfikacji parametrycznej:

- (a) Może być w prosty sposób zautomatyzowana (nie wymaga ingerencji projektanta modelu)
- (b) Ma charakter iteracyjny, podobnie jak każdy proces projektowy
- (c) Wykorzystuje dostępną wiedzę wstępną o identyfikowanym systemie
- (d) Ogranicza się do wyznaczania (estymacji) parametrów modelu

Wyjaśnienie:

Teoretycznie ma charakter iteracyjny – może wykorzystywać iteracyjne metody optymalizacji jeżeli nie jesteśmy w stanie jawnie wyznaczyć wzoru $\hat{p}_n$. Wykorzystujemy zbiór pomiarowy w którym są pomiary y i u . W tej metodzie chcemy znaleźć najlepszy model w sensie jakiegoś przyjętego kryterium jakości.

6. Dany jest model systemu $a(t)\ddot{y}(t) + b\dot{y} + c\sin(y) = ku^3(t)$, gdzie $k, b, c > 0$ są stałymi parametrami, natomiast $a(t) = A\sin(t)$ jest parametrem zmiennym w czasie. Wówczas można powiedzieć, że:

- (a) Model opisuje system stochastyczny
- (b) Model opisuje system niestacjonarny
- (c) Charakterystyka statyczna systemu przechodzi przez punkt $(u, y) = (0, 0)$
- (d) W tak przyjętym opisie systemu nie jest istotny stan przejściowy odpowiedzi $y(t)$

Wyjaśnienie:

Nie ma w tym modelu żadnych elementów losowych, natomiast system jest niestacjonarny bo parametry są zmienne w czasie. Charakterystyka statyczna przechodzi przez punkt $(0, 0)$, widać to gdy wyzerujemy pochodne i za u i y podstawimy 0. Stan przejściowy jest istotny w każdym systemie dynamicznym zwłaszcza gdy występują w nich kolejne pochodne zależne od czasu.

7. Analiza korelacyjna:

- (a) Należy do nieparametrycznych metod identyfikacji parametrów
- (b) Wymaga znalezienia parametrycznego modelu identyfikacji systemu dynamicznego
- (c) Polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego
- (d) Polega na oszacowaniu funkcji korelacji wzajemnej sygnału wyjściowego y z sygnałem wejściowym u systemu dynamicznego

Wyjaśnienie:


Ta metoda należy do metod nieparametrycznych – szacujemy tu skończoną sekwencję liczby próbek odpowiedzi impulsowej dynamiki. Warto dodać że w tej metodzie u i v są ze sobą wzajemnie nieskorelowane, y i u są ale to nie jest głównym celem tej metody.

8. Analiza korelacyjna obiektu opisanego równaniem $y(n) = \sum_{i=0}^{\infty} g_0(i)u(n-1) + v(n)$:

- (a) Polega na oszacowaniu skończonej liczby punktów charakterystyki statycznej
- (b) Wymaga znalezienia parametrycznego modelu identyfikowanego obiektu dynamicznego
- (c) Polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej obiektu dynamicznego
- (d) Wymaga nieskorelowania sygnału wejściowego $u(n)$ z zakłóceniem stochastycznym $v(n)$

Wyjaśnienie:

Analiza korelacyjna to metoda nieparametryczna więc z bomby można odrzucić odpowiedź b, sama metoda polega na szacowaniu skończonej liczby próbek odpowiedzi impulsowej obiektu – więc z automatu odpada także odpowiedź a. Natomiast odpowiedź d jest poprawna bo w tej metodzie sygnał wejściowy nie może być skorelowany z zakłóceniem stochastycznym.



Rysunek 1: Wykresy do zadan 9,10,11

9. Wykres na rysunku 1(a) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu linowego o transmitancji ściśle właściwej, przy czym skok pobudzenia o amplitudzie $A_u = 10$ podano w chwili $t = 2s$. Na podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że:
- (a) Wzmocnienie statyczne obiektu wynosi 0.5
 - (b) W transmitancji systemu występuje człon opóźniający e^{-sT_0} w którym $T_0 > 3s$
 - (c) Transmitancja systemu posiada przynajmniej dwa bieguny rzeczywiste
 - (d) W transmitancji systemu występuje dodatnie zero

Wyjaśnienie:

Wzmocnienie statyczne wynosi 0.05 -> podzielić maksymalną wartość odpowiedzi skokowej przez amplitudę. TRZEBA CZYTAĆ, pobudzenie podano dopiero po czasie 2s zatem opóźnienie będzie wynosić 2 s więc odpowiedź b odpada. Drogą eliminacji zostają odpowiedzi c oraz d (nieminimalnofazowy).

10. Wykres na rysunku 1(b) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu linowego o transmitancji ściśle właściwej, przy czym skok pobudzenia o amplitudzie $A_u = 2$ podano w chwili $t = 0s$. Na podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że:
- (a) W transmitancji systemu występuje człon opóźniający e^{-sT_0} w którym $T_0 > 3s$
 - (b) Wzmocnienie statyczne obiektu wynosi 0.5
 - (c) Transmitancja systemu posiada bieguny zespolone sprzężone
 - (d) W transmitancji systemu występuje zero w prawej półpłaszczyźnie zespolonej

Wyjaśnienie:

Widać z wykresu (a), że jest opóźnienie transportowe równe około 4s, natomiast podregulowanie może sugerować iż w układzie występuje zero w prawej półpłaszczyźnie – nieminimalnofazowość. Wzmocnienie statyczne obiektu jest mniejsze ($k_0 = \frac{0.5}{A_u} = 0.25$). Z tego przebiegu nie jesteśmy w stanie więcej stwierdzić.

11. Rysunek 1(b) ilustruje wynik analizy widmowej pewnego stabilnego i minimalnofazowego systemu $G_0(j\omega)$, uzyskany z wykorzystaniem dwóch estymatorów transmitancji $\hat{G}_N^*(j\Omega_k) = \frac{Y_N(j\Omega_k)}{U_N(j\Omega_k)}$ oraz $\hat{G}_N(j\Omega_k) = \frac{\Phi_{yu}^s(j\Omega_k)}{\Phi_{uu}^s(\Omega_k)}$. Na podstawie rysunku 1(b) możemy wnioskować, że:
- (a) Wariancja estymatora $\hat{G}_N^*(j\Omega_k)$ jest większa niż wariancja estymatora $\hat{G}_N(j\Omega_k)$
 - (b) Transmitancja identyfikowanego systemu ma wyłącznie bieguny rzeczywiste
 - (c) Pasma przenoszenia identyfikowanego systemu wynosi $[0; \omega_c]$, gdzie $\omega_c > 1 \frac{rad}{s}$
 - (d) Identyfikowany system posiada wzmocnienie statyczne $|k_o| \in [0; 1)$
 - (e) Wynik $\hat{G}_N^*(j\Omega_k)$ na podstawie danych zakłóconych losowo, natomiast wynik $\hat{G}_N(j\Omega_k)$ na podstawie danych bez zakłóceń
 - (f) Transmitancja identyfikowanego systemu ma przynajmniej dwa bieguny zespolone sprzężone
 - (g) 3-dB pasmo przenoszenia identyfikowanego systemu wynosi $[0; \omega_c]$, gdzie $\omega_c < 1 \frac{rad}{s}$
 - (h) Identyfikowany system posiada wzmocnienie statyczne $k_o < 0$

Wyjaśnienie:

Na rysunku widać, że powstał pik rezonansowy, co może sugerować rząd dynamiki większy równy 2 i dodatkowo są tam zespolone sprzężone mody. Odpowiedź e jest nieprawidłowa, ponieważ oba estymatory mają zakłócenia. Odpowiedź f jest prawidłowa, ponieważ pik rezonansowy na wykresie Bode'go sugeruje, że transmitancja ma bieguny zespolone sprzężone. Natomiast z wykresu idzie także odczytać pasmo przenoszenia, które wynosi ok. $\omega_c > 1$

12. Dane jest równanie modelu systemu: $y^{(2)} + y^{(1)} + y^{(p_1)} = p_2 u$, gdzie p_1 i p_2 są szukanymi parametrami modelu, y jest sygnałem wyjściowym, u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas:

- (a) Charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := \ln y$ i $u^* := \ln u$
- (b) Identyfikacja modelu charakterystyki statycznej systemu wymaga oszacowania sygnałów $y^{(2)}$ i $y^{(1)}$
- (c) Model odwzorowania wejścia sterującego w wyjście w stanie ustalonym ma postać: $y^{(p_1)} = p_2 u$
- (d) Charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := y^{(p_1)}$ i $u^* := u$

Wyjaśnienie:

W stanie ustalonym, gdy pochodne sygnału wyjściowego są równe zero, to model upraszcza się do formy z odpowiedzi c, co odpowiada charakterystyce statycznej systemu. Charakterystykę statyczną systemu można przedstawić w formie liniowej, co też widać w odpowiedzi d.

13. Dane jest równanie modelu systemu: $y^{(2)} + p_4 y^{(1)} + p_3 y^{(p_1)} = p_2 u$, gdzie $i = 1, \dots, 4$ są parametrami modelu, y jest sygnałem wyjściowym, u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas:

- (a) Charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := \log y$ i $u^* := \log u$
- (b) Model regresyjny odwzorowania wejścia u w wyjście y w stanie ustalonym ma 2 niezależne parametry
- (c) Identyfikacja modelu charakterystyki statycznej systemu wymaga oszacowania sygnałów $y^{(2)}$ i $y^{(1)}$
- (d) Charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := y^{(p_1)}$ i $u^* := u$

Wyjaśnienie:

Tutaj to chuj wie A raczej git B nie wiem

14. Jeżeli model systemu opisano równaniem $y(n) + ay(n-1) = -bu(n-3) + C(q^{-1})e(n)$, gdzie $e(n)$ jest szumem białym, a $C(q^{-1})$ jest wielomianem operatora q^{-1} , wówczas:
- (a) Powyższy model należy do modeli typu ARMAX, jeżeli $C(q^{-1}) = 1$
 - (b) Przy zapisie regresyjnym dla $C(q^{-1}) = 1$ wektor regresji ma postać: $\varphi(n) = [-y(n-1) - u(n-3)]^T$
 - (c) Dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny: $H(q^{-1}) = \frac{C(q^{-1})}{1+aq^{-1}}$
 - (d) Dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny: $H(q^{-1}) = \frac{bq^{-3}}{1+aq^{-1}}$

Wyjaśnienie:

Gdy sobie uprościmy $C(q^{-1}) = 1$ to otrzymamy ładną postać regresyjną, która zgadza się z odpowiedzią b, natomiast dynamika toru zakłócenia przyjmie postać z odpowiedzi c – podzielić sobie przez to co stoi przy $y(n-1)$.

15. Jeżeli dynamikę systemu opisuje następujące równanie $y(n) + ay(n-1) = bu(n-1) + e(n)$ gdzie $e(n)$ jest szumem białym wówczas:
- (a) Dynamikę toru sterowania w modelu definiuje operator transmitancyjny: $G(q) = \frac{1+aq^{-1}}{bq^{-1}}$
 - (b) Wektor regresji przyjmuje postać: $\varphi^T(n) = [-y(n-1) - u(n-1)]^T$
 - (c) Dynamikę toru zakłócenia w systemie definiuje wyrażenie $H(q^{-1}) = \frac{1}{1+aq^{-1}}$
 - (d) Dynamikę toru zakłócenia w systemie definiuje wyrażenie $H(q)=1$

16. Jeżeli model systemu opisano równaniem $y(n) + ay(n-1) = -bu(n-3) + ce(n-1) + e(n)$, gdzie $e(n)$ jest szumem białym, wówczas:

- (a) Powyższy model należy do typu ARX, jeżeli $c = 1$
- (b) Przy zapisie regresyjnym dla $c = 0$ wektor regresji ma postać $\varphi(n) = [-y(n-1) - u(n-3)]^T$
- (c) Dynamikę toru zakłócenia w modelu definiuje operator transmitancyjny: $H(q^{-1}) = \frac{1-cq^{-1}}{1+aq^{-1}}$
- (d) Dynamikę toru sterowania w modelu definiuje operator transmitancyjny: $G(q^{-1}) = \frac{1-bq^{-3}}{1+aq^{-1}}$

Wyjaśnienie:

Odpowiedź a odpada bo jak damy $c = 1$ to mamy opóźniony błąd co nie występuje w modelu ARX. Zapis regresyjny się zgadza bo kasuje nam się składnik $ce(n-1)$, dodatkowo odpowiedź c też jest poprawna (sprawdzone na kartce) – tor zakłócenia się zgadza z odpowiedzią.

17. System generujący dane pomiarowe ma postać: $y^{(2)}(t) + p_{10}y^{(1)} + p_{30}y(t) = p_{20}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $y(t)$ oraz $u(t)$, wówczas model $y^{(2)}(nT_p) = [-y^{(1)}(nT_p) - y(nT_p) \ u(nT_p)]p + v(nT_p)$, $p = [p_1, p_2, p_3]^T$ Wyjaśniający dane pomiarowe próbkowane z okresem $T_p > 0$:

- (a) Jest modelem czasu dyskretnego
- (b) Zachowuje oryginalną strukturę systemu czasu ciągłego
- (c) Wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego
- (d) Wymaga zastosowania filtrów SVF, jeżeli ma być użyty do estymacji metodą LS parametrów strukturę systemu czasu ciągłego

Wyjaśnienie:

Przekształcenie zmienia strukturę modelu na model czasu dyskretnego, natomiast użycie filtracji SVF pomaga w lepszym zachowaniu właściwości dynamicznych systemu czasu ciągłego w jego modelu czasu dyskretnego.

18. System generujący dane pomiarowe ma postać: $y^{(2)}(t) + p_{10}y^{(1)} = p_{20}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $y(t)$ oraz $u(t)$, wówczas model wyjaśniający dane pomiarowe próbkowane z okresem $T_p > 0$:
- (a) Postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p)u(nT_p)]p + v(nT_p)$ nie jest użyteczny w praktyce
 - (b) Postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p)u(nT_p)]p + v(nT_p)$ zachowuje strukturę systemu czasu ciągłego
 - (c) Postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p)u(nT_p)]p + v(nT_p)$ jest modelem czasu dyskretnego
 - (d) Wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego

Wyjaśnienie:

Przekształcenie zmienia strukturę modelu na model czasu dyskretnego, natomiast użycie filtracji SVF pomaga w lepszym zachowaniu właściwości dynamicznych systemu czasu ciągłego w jego modelu czasu dyskretnego.

19. System generujący dane pomiarowe ma postać: $y(n) = [y(n-1) \ y(n-2) \ u(n-2)]p_0 + e(n)$, gdzie p_0 jest wektorem parametrów prawdziwych, w $e(n)$ jest szumem białym. Jeżeli symbolem $\hat{p}$ oznaczmy estymatę wektora parametrów modelu tego systemu, wówczas:
- (a) Odpowiedź optymalnego predyktora ma postać $\hat{y}(n|n-1) = [y(n-1) \ y(n-2) \ u(n-2)]\hat{p}$
 - (b) Odpowiedź optymalnego predyktora ma postać $\hat{y}(n|n-1) = [y(n-1) \ y(n-2) \ u(n-2)]p_0$
 - (c) Odpowiedź modelu symulowanego ma postać $y_m(n) = [y_m(n-1) \ y_m(n-2) \ u(n-2)]\hat{p}$
 - (d) Odpowiedź modelu symulowanego ma postać $y_m(n) = [y(n-1) \ y(n-2) \ u(n-2)]\hat{p}$

Wyjaśnienie:

W przypadku modelu symulowanego odpowiedź zależy od poprzednich próbek odpowiedzi symulatora, natomiast dla predyktora zależy od poprzednich próbek odpowiedzi systemu i predyktora.

20. System generujący dane pomiarowe ma postać: $y(n) = \frac{p_{20}q^{-2}}{1-p_{10}q^{-1}}u(n) + \frac{1}{1-p_{10}q^{-1}}e(n)$, gdzie $p_0 = [p_{10} \ p_{20}]^T$ jest wektorem parametrów prawdziwych, w $e(n)$ jest szumem białym. Jeżeli symbolem $\hat{p}$ oznaczmy estymatę wektora parametrów modelu tego systemu, wówczas:
- (a) Optymalnego predyktora jednokrokowego ma postać $\hat{y}(n|n-1) = y(n-1) \ u(n-2)]\hat{p}$
 - (b) Optymalnego predyktora jednokrokowego ma postać $\hat{y}(n|n-1) = \hat{y}(n-1|n-1) \ u(n-2)]\hat{p}$
 - (c) Model symulowanego ma postać $y_m(n) = [y(n-1) \ u(n-2)]\hat{p}$
 - (d) Model symulowanego ma postać $y_m(n) = [y_m(n-1) \ u(n-2)]\hat{p}$

Wyjaśnienie:

Pierwsza odpowiedź to poprawna postać predyktora, druga jest bez sensu bo by to robił w kółko do skończenia próbek, trzecia odpowiedź bierze odpowiedź oryginału czego nie chcemy w przypadku modelu symulowanego więc ostatnia odpowiedź jest poprawna.

21. Dany jest model czasu dyskretnego $y(n) = \frac{bq^{-2}}{1+aq^{-1}}u(n) + \frac{1+cq^{-1}}{1+aq^{-1}}e(n)$, gdzie $e(n)$ jest szumem białym, natomiast $a \neq 0$, $b \neq 0$ i $c \neq 0$ są parametrami modelu. Wówczas:
- (a) Model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2) \ e(n-1)]p + e(n)$, gdzie $p = [a \ b \ c]^T$
 - (b) Model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2)]p + v(n)$, przy czym $p = [a \ b]^T$ oraz $v(n) = e(n) + ce(n-1)$
 - (c) Model jest nieprzyczynowe ze względu na wejściu u
 - (d) Model jest typu ARX

Wyjaśnienie:

Po przekształceniu modelu do postaci regresyjnej otrzymamy odpowiedź a oraz b. Model jest przyczynowy oraz nie jest to model ARX tylko ARMAX.

22. Dane jest równanie estymatora $\hat{p}_N = (\Phi^T \Phi)^{-1} \Phi^T y$ gdzie Φ jest stochastyczna macierzą regresji (tj. elementy macierzy Φ zależą od stochastycznego zakłócenia v obecnego w równaniu $y = \varphi^T p + v$), a $N \gg \dim(\hat{p}_N)$ jest liczbą par $\{u_n, y_n\}$ danych pomiarowych. Wówczas:
- (a) Powyższy estymator jest nieobciążony, jeżeli wartość oczekiwana zakłócenia v jest zerowa
 - (b) Aby powyższy estymator był zgodny, zakłócenie stochastyczne v musi być szumem białym
 - (c) Powyższy estymator gwarantuje zbieżność $\hat{p}_N$ do parametrów prawdziwych p_0 jeżeli tylko $N \rightarrow \infty$
 - (d) Aby powyższy estymator był zgodny, struktura wektora regresji φ musi odpowiadać strukturze wektora φ_0 prawdziwego systemu

Wyjaśnienie:

O to nam chodzi żeby struktura wektora regresji odpowiadała jak najbardziej strukturze wektora prawdziwego i przy okazji parametrom prawdziwym, szum biały jest ok bo nam to dosyć upraszcza – w przypadku kolorowego są bardziej skomplikowane wzory i przeważnie nie osiągniemy zgodności.

23. Estymator metody najmniejszych kwadratów błędów równaniowych (LS):

- (a) Znajduje zastosowanie tylko do modeli systemów liniowych
- (b) Wynika z minimalizacji kryterium: $V_n = \frac{1}{2} \sum_{n=1}^N |y(n) - \hat{y}(n|n-1)|$
- (c) Przyjmuje jawną postać równania, gdy błąd równaniowy zależy liniowo od parametrów modelu
- (d) Może prowadzić do obciążonych estymat parametrów modelu

Wyjaśnienie:

Metoda LS może prowadzić do estymat obciążonych/nieobciążonych i jeżeli mamy liniową zależność błędu równaniowego od parametrów to jesteśmy jawnie zapisać to równanie. Odpowiedź b to jedno z wielu kryterium jakim można minimalizować tą metodę, natomiast ta metoda ma też zastosowanie do modeli nieliniowych.

24. Metoda identyfikacji najmniejszych kwadratów

- (a) Znajduje zastosowanie tylko do modeli systemów liniowych
- (b) Wynika z minimalizacji kryterium: $V_n = \frac{1}{2} \sum_{n=1}^N |y(n) - \hat{y}(n|n-1)|$
- (c) Korzysta z liniowej parametryzacji modelu sytemu
- (d) Może prowadzić do nieobciążonych estymatorów parametrów modelu

25. Równanie $\hat{p}_{LS} = (\Phi^T \Phi)^{-1} \Phi^T y$

- (a) Określa optymalny wektor parametrów wsadowej metody najmniejszych kwadratów
- (b) Jest tożsamy z $\hat{p}_{LS} \Phi^- y$ gdzie $\Phi^- y$ jest pseudoodwrotnością lewostronna
- (c) Jest tożsamy z $\hat{p}_{LS} \Phi^- y$ gdzie $\Phi^- y$ jest pseudoodwrotnością prawostronna
- (d) Określa estymator parametrów rekurencyjnej metody najmniejszych kwadratów

26. Dane jest równanie estymatora $\hat{p}_N = (\Phi^T \Phi)^{-1} \Phi^T y$ gdzie Φ jest deterministyczną macierzą regresji (tj. elementy macierzy Φ nie są skorelowane ze stochastycznym zakłóceniem v z równania $y = \varphi^T p + v$), a $N \gg \dim(\hat{p}_N) = \dim(p)$ jest liczbą par $\{u_n, y_n\}$ danych pomiarowych. Wówczas:

- (a) Aby powyższy estymator był nieobciążony, wartość oczekiwana zakłócenia kolorowego v musi być zerowa
- (b) Aby powyższy estymator był nieobciążony, zakłócenie stochastyczne v musi być szumem białym
- (c) Macierz kowariancji $Cov[\hat{p}_N] = \sigma_0^2 (\Phi^T \Phi)^{-1}$ niezależnie od koloru zakłócenia v
- (d) Aby powyższy estymator był nieobciążony, macierz Φ musi być pełnego rzędu równego $\dim(p)$

Wyjaśnienie:

Jednym z podstawowych założeń dla tego estymatora który jest deterministyczny jest to że przyjmujemy zakłócenia jako szum biały, wtedy estymator jest nieobciążony – odpowiedź poprawna czyli ma: $E[\hat{p}_N^{LS}] = p_0$. Odpowiedź d jest poprawna bo gdyby nie była pełnego rzędu to ciężko byłoby nam obliczyć estymator jeżeli mielibyśmy mniejszy rząd niż liczbę parametrów. Macierz kowariancji jest określona dla szumu białego – w przypadku szumu kolorowego te wzory są bardzo skomplikowane. Drogą eliminacji pozostałe odpowiedzi odpadają.

27. Dane jest równanie estymatora $\hat{p}_N = (Z^T \Phi)^{-1} Z^T y$ gdzie Φ jest stochastyczną macierzą regresji (tj. elementy macierz regresji są skorelowane ze stochastycznym zakłóceniem v z równania $y = \varphi^T p + v$), Z jest macierzą zmiennych instrumentalnych, natomiast $N \gg \dim(\hat{p}_N) = \dim(p)$ jest liczbą par danych pomiarowych. Wówczas:

- (a) Powyższy estymator jest najefektywniejszy, jeżeli wartość oczekiwana zakłócenia $v(n)$ jest zerowa
- (b) Powyższy estymator może być zgodny tylko jeżeli zakłócenie v jest szumem białym
- (c) Powyższy estymator może być zgodny jeżeli elementy Z są skorelowane z elementami Φ
- (d) Powyższy estymator może być zgodny, jeżeli elementy Z nie są skorelowane z zakłóceniem v

Wyjaśnienie:

Można wywnioskować po dwóch ostatnich odpowiedziach, elementy macierzy Z są silnie skorelowane z macierzą regresji i nieskorelowane z zakłóceniem – główny zamysł tej metody. Metoda IV nie modeluje toru zakłócenia.

28. Znana jest struktura identyfikowanego systemu dynamicznego $y(n) = \frac{b_0 q^{-1}}{1+a_0 q^{-1}} u(n) + \frac{1+c_0 q^{-1}}{1+a_0 q^{-1}} e(n)$ przy czym $e(n)$ jest szumem białym, a $a_0 \neq 0, b \neq 0$ oraz c_0 są nieznanymi parametrami prawdziwymi. Parametryczna identyfikacja systemu w układzie otwartym metodą najmniejszych kwadratów błędów równaniowych (LS):

- (a) Może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu jeżeli $c_0 = a_0$
- (b) Gwarantuje zgodną estymację parametrów $p = [a \ b]^T$ modelu, gdy tylko $u(n)$ jest szumem białym
- (c) Asymptotycznie prowadzi do statystycznie równoważnych wyników estymacji niezależnie czy stosujemy wersję wsadową LS czy rekursywną RLS
- (d) Może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ jeżeli $c_0 = 0$

Wyjaśnienie:

Z własności obu metod wynika, gdy n próbek dąży do nieskończoności to obie metody powinny dawać równoważne wyniki, natomiast gdy współczynnik c_0 będzie równy zero to zakłócenie przyjmuje formę szumu białego co w konsekwencji może doprowadzić do zgodności estymatora. $U(n)$ jako szum biały to słaby pomysł. Gdy parametr $c_0 = 0$ to model upraszcza nam się do modelu ARX dla niego metoda LS działa dobrze co może prowadzić do zgodności estymatora. Asymptotyczność prowadzi do tego że metody LS i RLS dają podobne lub te same wyniki.

29. W równaniu $\hat{y}(n) = \varphi^T(n) \hat{p} + v(n)$

- (a) $v(n) = C(q^{-1})\varepsilon(n)$ reprezentuje szum biały
- (b) $\varphi^T(n)$ reprezentuje wektor zmiennych regresji
- (c) Składowymi wektora regresji mogą być opóźnione w czasie próbki mierzonego sygnału $y(n)$
- (d) Element $\hat{p}$ jest wektorem znanych (prawdziwych) parametrów modelu obiektu

30. Jeżeli dynamikę systemu opisuje następujące równanie $A(q^{-1})y(n) = B(q^{-1})u(n) + C(q^{-1})e(n)$ gdzie $e(n)$ jest szumem białym Wówczas:

- (a) Model powyższy określany jest mianem modelu ARMAX
- (b) Model powyższy określany jest mianem modelu ARMA

- (c) Postać wielomianu $C(q^{-1})$ decyduje o kolorze szumu $C(q^{-1})e(n)$
 - (d) Wielomian $B(q^{-1})$ jest wielomianem monicznym
31. Rzeczywisty system dynamiczny generujący dane pomiarowe ma postać $y = \varphi_0^T p_0 + v$ gdzie φ oznacza prawdziwą strukturę wektora regresji, a p_0 reprezentuje wektor prawdziwych parametrów systemu. Estymator LS zastosowany do modelu $y = \varphi^T p + v$ w celu parametrycznej identyfikacji systemu w układzie otwartym:
- (a) Może posiadać własność zgodności, jeżeli dane pomiarowe zawierają wystarczająco bogatą informację o systemie
 - (b) Zawsze zwraca estymaty $\hat{p}_N$ równe p_0 (z prawdopodobieństwem 1), gdy liczba danych $N \rightarrow \infty$
 - (c) Może mieć własność zgodności, jeżeli model wyjaśniający dane $y = \varphi^T p + v$ będzie taki, że $\varphi = \varphi_0$ oraz v będzie szumem białym
 - (d) Będzie miał własność zgodności, jeżeli tylko v będzie szumem białym

Wyjaśnienie:

Jeżeli dane są wystarczająco bogate to są w stanie zapewnić identyfikowalność wszystkich parametrów modelu, natomiast jeżeli struktura modelu regresji jest dokładnie taka sama jak struktura prawdziwa i zakłócenia są szumem białym to estymator będzie zgodny – szum biały nie wprowadza systematycznego błędu w oszacowywaniu parametrów.

32. Parametryczna identyfikacja systemu $y = \varphi^T p_0 + v$ w układzie otwartym metodą zmiennych instrumentalnych:
- (a) Zawsze daje lepsze wyniki estymacji parametrów niż te uzyskane metodą LS niezależnie od charakteru zakłócenia v
 - (b) Pozwala na uzyskanie zgodnych estymat parametrów nawet, gdy zakłócenie v jest kolorowe
 - (c) Wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z zakłóceniem v
 - (d) Wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z elementami wektora φ

Wyjaśnienie:

Metoda IV jest stosowana kiedy np. metoda LS nie jest skuteczna – może być wykorzystana do estymacji parametrów nawet gdy v jest kolorowe. Ważne jest to aby zdefiniować zmienne instrumentalne które nie są skorelowane z zakłóceniem v , natomiast zmienne instrumentalne są silnie skorelowane z wektorem parametrów. Metoda IV kładzie szczególny nacisk na estymację parametrów toru sterowania, a tor zakłócenia nie jest identyfikowany w podstawowej metodzie IV.

33. Metoda identyfikacji RELS:

- (a) Umożliwia estymację parametrów wielomianu $C(q^{-1})$ modelu ARMAX
- (b) Jest zalecana w przypadku gdy błąd równaniowy jest szumem białym
- (c) Daje taką samą jakość estymacji jak metoda RLS gdy szum biały działający na system jest kolorowy
- (d) Jest dedykowana dla modelu ARX
- (e) Wykorzystuje opóźnione próbki błędów predykcji w wektorze regresji

Wyjaśnienie:

Ta metoda głównie wykorzystuje model ARMAX, który umożliwia bardziej elastyczne modelowanie toru zakłócenia. Wykorzystuje ona także opóźnione próbki błędów predykcji w wektorze regresji: $\hat{e}(n) = y(n) - \varphi^T(n)\hat{p}(n-1)$.

34. Rekursywna metoda najmniejszych kwadratów wyznaczająca estymatę $\hat{p}(n)$:

- (a) Wynika z równania aktualizacji: $\hat{p}(n) = \hat{p}(n-1) + k \in (n)$, gdzie $k = \text{const}$
- (b) W wersji podstawowej skutkuje stopniową utratą zdolności adaptacyjnych estymatora, gdy $n \rightarrow \infty$
- (c) W wersji RLS_λ po zastosowaniu współczynnika zapominania $\lambda \in (0; 1)$ pozwala na śledzenie wolno-zmiennych parametrów $p_0(n)$ systemu rzeczywistego
- (d) Musi być wykonywana w trybie on-line, tj. w czasie rzeczywistym i równoległe do działającego systemu rzeczywistego
- (e) Daje estymatory obciążone gdy szum działający na system jest szumem kolorowym
- (f) Pozwala na śledzenie zmiennych w czasie parametrów systemu gdy współczynnik zapominania $\lambda = 1$

Wyjaśnienie:

W odpowiedzi a, współczynnik k nie jest stały, zależy od macierzy kowariancji błędów oraz aktualnej wartości wektora regresji. Odpowiedź b jest poprawna z tego względu, że w podstawowej wersji metody RLS estymator z czasem staje się mniej wrażliwy na nowe dane co prowadzi do utraty adaptacyjności. Odpowiedź c jest poprawna, ponieważ współczynnik zapominania umożliwia estymatorowi większą adaptacyjność. Odpowiedź d jest niepoprawna bo nie ta metoda niekoniecznie musi być wykonywana on-line.

35. Dla systemu dynamicznego $y(n) = [-y(n-1) \ u(n-2)]p_0$, gdzie $p_0 = \text{const}$, uzyskano obciążone estymaty $\hat{p}_N^{LS}$ parametrów. Aby zmniejszyć lub usunąć obciążenie można:

- (a) Wyznaczyć wartości obciążenia i odjąć je od estymat w wektorze $\hat{p}_N^{LS}$
- (b) Zastosować estymację z użyciem dwuetapowej metody zmiennych instrumentalnych IV|LS
- (c) Zwiększyć stopnie wielomianów $A(q^{-1})$ i $B(q^{-1})$ modelu i zastosować ponownie metodę LS
- (d) Zastosować metodę RLS z resetowaniem macierzy kowariancyjnej

Wyjaśnienie:

Odpowiedź a wydaje się dziwna i niepraktyczna, b jest to książkowe podejście, a c to jeden ze sposobów zmniejszania też opisany w książce. Resetowanie macierzy kowariancyjnej w metodzie RLS może poprawiać śledzenie parametrów w czasie ale raczej nie zmniejsza lub usuwa obciążenia.

36. Adaptacyjna identyfikacja zmiennych parametrów $p_0(n)$ systemu rzeczywistego metodą RLS z wykorzystaniem mechanizmu resetowania macierzy kowariancyjnej $P(n)$:

- (a) Polega na zerowaniu macierzy $P(n)$ w chwili wykrycia zmian parametrów systemu
- (b) Jest zalecana w przypadku wolnozmiennych lecz ustawicznych zmian parametrów $p_0(n)$
- (c) Może skutkować nagłą zmianą estymat parametrów modelu zaraz po resecie macierzy $P(n)$
- (d) Polega na podstawieniu pod $P(n)$ wybranej macierzy dodatnio określonej
- (e) Polega na podstawieniu pod $P(n)$ macierzy diagonalnej o nieujemnych elementach diagonalnych

Wyjaśnienie:

Resetowanie macierzy $P(n)$ zalecane jest w przypadku nagłych zmian w parametrach systemu, które mogą pochodzić z jego modyfikacji lub modyfikacji warunków pracy. Reset macierzy kowariancyjnej polega na podstawieniu pod nią nowej macierzy dodatnio określonej o dużych wartościach na przekątnej, co pozwala zapomnieć przeszłe dane i nadać większą wagę nowym.

37. Dany jest system rzeczywisty $y(n) = [y(n-1) \ u(n-2)]p_0 + v(n)$, z którego zebrano dane pomiarowe $Z^N = \{y(n), u(n)\}$ i wyznaczono obciążone estymaty $\hat{p}^{LS} = [\hat{p}_1^{LS} \ \hat{p}_2^{LS}]^T$ modelu o tej samej strukturze wektora regresji. Stosując metodą identyfikacji typu RIV zmienne instrumentalne:

- (a) można wybrać następująco $z \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n-1) = [y(n-2) \ u(n-3)]\hat{p}^{IV}(n-1)$
- (b) można wybrać następująco $z \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n-1) = [x(n-2) \ u(n-3)]\hat{p}^{LS}$

- (c) można wybrać następująco $z \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n) = [x(n-1) \ u(n-2)]\hat{p}^{IV}(n-1)$
- (d) można wybrać następująco $z \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n) = [y(n-1) \ u(n-2)]\hat{p}^{LS}$

Wyjaśnienie:

$$\begin{aligned} y(n) &= [y(n-1) \ u(n-2)]p_0 + v(n) \\ z(n) &= [x(n-1) \ u(n-2)]^T \\ x(n-1) &= [y(n-2) \ u(n-3)]\hat{p}^{IV}(n-1) \end{aligned}$$


Cokolwiek to znaczy.

38. Identyfikacja obiektu objętego ujemnym sprzężeniem zwrotnym w układzie regulacji z konwencjonalnym liniowym regulatorem o stałych parametrach:

- (a) Jest zalecana ze względu na gwarancję nieustannego pobudzenia systemu sygnałem sterującym
- (b) Wymaga pomiaru sygnału wyjściowego oraz sygnału zadanego
- (c) Zwykle daje lepsze wyniki identyfikacji niż w układzie otwartym
- (d) Może prowadzić do niejednoznacznej estymacji parametrów modelu ze względu na zależność sygnału wejściowego obiektu od jego odpowiedzi
- (e) Może prowadzić do obciążenia estymacji parametrów modelu ze względu na zależność sygnału wejściowego obiektu od sygnału wyjściowego
- (f) Może być konieczna, aby zapewnić ograniczoną odpowiedź identyfikowanego systemu

Wyjaśnienie:

Generalnie identyfikacja w układzie otwartym daje lepsze efekty niż w zamkniętym, ponieważ w układzie zamkniętym może być niejednoznaczna (źle uwarunkowana).



Rysunek 2: Gęstość widmowa do zadania 39

39. Wykres na rysunku 2 przedstawia gęstość widmową mocy zaprojektowanego sygnału pobudzającego typu GBN w funkcji pulsacji unormowanej. Na podstawie wykresu można stwierdzić, że:

- (a) Sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{ks}{1+sT}$, $T > 0$
- (b) Sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{k}{1+sT}$, $T > 0$
- (c) Sygnał ten jest nieustannie pobudzający rzędu $\delta_u < 4$
- (d) Sygnał ten jest nieustannie pobudzający rzędu $\delta_u > 12$
- (e) Sygnał ten nadaje się do estymacji parametrów modelu typu ARX, w którym $n_a \leq 8$ i $n_b \leq 4$

- (f) Sygnał ten jest nieustannie pobudzający dla rzędu $\delta_u < 3$
- (g) Sygnał ten ma charakter binarnego szumu czerwonego

Wyjaśnienie:

Warto zapamiętać że: $\delta \geq n_a + n_b$ rząd nieustannego pobudzenia który sprawia że eksperyment identyfikacyjny jest wystarczająco informatywny.

40. Wybór okresu próbkowania $T_p > 0$ sygnałów $u(t)$ oraz $y(t)$ do celów parametrycznej identyfikacji modelu czasu dyskretnego:
- (a) Jest właściwy, jeżeli $T_p \sim \frac{T}{10}$, gdzie $T > 0$ jest dominującą stałą czasową systemu czasu ciągłego
 - (b) Generalnie jest tym lepszy, im mniejsza wartość T_p
 - (c) Nie ma wpływu na jakość identyfikacji gdy tylko spełnia twierdzenie o próbkowaniu
 - (d) Sugeruje mniejsze wartości T_p gdy model ma być lepiej dopasowywany w zakresie wyższych częstotliwości

Wyjaśnienie:

Odpowiedź a spełnia praktyczne zalecenia dotyczące wyboru okresu próbkowania w stosunku do stałej czasowej systemu, natomiast w odpowiedzi d mniejszy okres próbkowania pozwala lepiej odwzorować sygnał w wyższych częstotliwościach – wyższe częstotliwości wymaga

41. Rząd δ_u nieustannego pobudzenia systemu $u(n)$ stosowanego podczas eksperymentu identyfikacyjnego:
- (a) Nie ma wpływu na zbieżność estymat parametrów modelu przy identyfikacji metodą RIV
 - (b) Jest związany z liczbą składowych częstotliwościowych zawartych w sygnale $u(n)$
 - (c) Jest dowolnie duży, jeżeli $u(n)$ jest szumem białym
 - (d) Powinien być taki że $\delta_u > \dim(p)$ gdzie p jest wektorem parametrów modelu toru sterowania
 - (e) Jest równy 2, gdy ma on postać sumy dwóch składowych sinusoidalnych o różnych pulsacjach
 - (f) Jest równy 2 gdy ma on postać funkcji impulsowej
 - (g) Jest równy 2 gdy ma on postać funkcji sinusoidalnej

Wyjaśnienie:

Rząd sygnału pobudzającego jest bezpośrednio związany z liczbą składowych częstotliwościowych, aby móc dokładnie zidentyfikować model systemu liczba składowych sygnału pobudzającego musi być większa od liczby parametrów modelu. W przypadku pojedynczej funkcji sinusoidalnej ($k = 1$), rząd wynosi $2 \cdot 1 = 2$.

42. Współczynnik szczytu C_r sygnału pobudzającego $u(n)$:
- (a) Zaleca się aby był jak największy podczas eksperymentu identyfikacyjnego
 - (b) Ma wartość $C_r = 0.5$, gdy $u(n)$ jest sygnałem typu suma sinusów
 - (c) Ma wartość $C_r = 0.5$, gdy $u(n)$ jest sygnałem typu suma sinusów o fazach Schroedera
 - (d) Ma wartość $C_r = 1$, gdy $u(n)$ jest sygnałem typu PRBS
 - (e) Zaleca się aby był jak najmniejszy podczas eksperymentu identyfikacyjnego
 - (f) Zaleca się aby był bliski jedności podczas eksperymentu identyfikacyjnego

Wyjaśnienie:

Sygnał PRBS ogranicza się do dwóch poziomów np. $+1$ i wartość skuteczna i maksymalna są dla niego równoznaczne co daje współczynnik szczytu równy 1, natomiast zaleca się aby współczynnik szczytu był jak najmniejszy podczas eksperymentu identyfikacyjnego, gdyż niższy współczynnik szczytu sygnału pobudzającego jest preferowany w celu zapewnienia lepszej jakości danych identyfikacyjnych i uniknięcia wpływu nieliniowości systemu.

43. Zebrano dwa zbiory Z_1 i Z_2 próbek sygnału wejściowego i wyjściowego pewnego systemu. Przeprowadzono identyfikację parametru p modelu tego systemu niezależnie dla obu zbiorów danych uzyskując estymaty: $\hat{p}_1$ (na podstawie zbioru Z_1) oraz $\hat{p}_2$ (na podstawie zbioru Z_2). Obliczono wartości wariancji v_1 i v_2 dla poszczególnych estymat. Optymalną (w sensie minimum wariancji) wypadkową estymatę parametru p oraz odpowiadającą jej wartość wariancji v uzyskamy gdy:
- (a) $\hat{p} = (v_2\hat{p}_1 + v_1\hat{p}_2)/(v_1 + v_2)$
 - (b) $\hat{p} = (\hat{p}_1 + \hat{p}_2)/(v_1 + v_2)$
 - (c) $(v_1 + v_2)/2$
 - (d) $v = v_1v_2/(v_1 + v_2)$
44. Filtracja filtrami analogowymi $F_u(s)$ i $F_y(s)$, odpowiednio sygnałów $u(t)$ oraz $y(t)$ pochodzących z wejścia i wyjścia identyfikowanego procesu liniowego o transmitancji $G_o(s, p_0)$:
- (a) Nie wpływa na jakość identyfikacji parametrycznej, jeżeli tylko filtry są jednakowe
 - (b) Jest zawsze konieczna w przypadku identyfikacji modelu czasu ciągłego
 - (c) Umożliwia dopasowanie modelu $G(j\omega, \hat{p})$ do wybranego zakresu częstotliwości
 - (d) Umożliwia zgodną identyfikację parametryczną modelu $G(s, \hat{p})$ o tej samej strukturze co $G_o(s, p_0)$

Wyjaśnienie:

Nawet jeżeli filtry są jednakowe to mogą one w różny sposób zmieniać charakterystykę sygnałów, w przypadku identyfikacji modelu czasu ciągłego zazwyczaj jest wymagana ale nie zawsze. W przypadku odpowiedzi c – filtracja może być użyta do skoncentrowania się na określonym paśmie częstotliwości co pozwala lepiej dopasować model do pasma. Odpowiedź d – odpowiednia filtracja może pomóc w uzyskaniu modelu o tej samej strukturze co identyfikowany proces.

45. Filtracja Kalmana

- (a) Może być zawsze utożsamiona z estymacją RLS
- (b) Pozwala na estymację struktury modelu systemu dynamicznego w oparciu o pomiar wyjścia w obecności zakłóceń stochastycznych
- (c) Pozwala na estymację stanu systemu dynamicznego w oparciu o pomiar wyjścia w obecności zakłóceń stochastycznych
- (d) Składa się z dwóch etapów: predykcji (estymacji a priori) oraz korekcji (estymacji a posteriori)

46. Weryfikacja wyznaczonego modelu parametrycznego:

- (a) W praktyce polega na porównaniu obliczonych estymat z prawdziwymi parametrami systemu
- (b) Dotyczy elastyczności, oszczędności i użyteczności modelu w danym zastosowaniu
- (c) Powinna sugerować wybór najoszczędniejszego modelu spośród wszystkich akceptowalnych modeli
- (d) Powinna być wykonywana z wykorzystaniem danych użytych do estymacji parametrów modelu

Wyjaśnienie:

Weryfikacja modelu często obejmuje ocenę, czy model jest odpowiednio elastyczny do modelowania różnych stanów systemu, natomiast w procesie selekcji modelu często stosuje się zasadę minimalizacji złożoności modelu przy zachowaniu odpowiedniej dokładności.

47. Praktyczna weryfikacja wyznaczonego użytkowego modelu parametrycznego $M(\hat{p})$:

- (a) Polega na sprawdzeniu jego użyteczności w danym zastosowaniu
- (b) Polega na porównaniu obliczonych estymat $\hat{p}_N$ z parametrami p_0 systemu prawdziwego
- (c) Powinna być wykonywana z wykorzystaniem tych samych danych, które użyto do estymacji parametrów modelu

- (d) W podejściu BLACK-BOX powinna sugerować wybór najoszczędniejszego modelu spośród wszystkich akceptowalnych modeli alternatywnych
48. Niech $y_m(n)$, $\hat{y}(n|n-1)$, $y(n)$ oraz $y_0(n)$ oznaczają, odpowiednio odpowiedź modelu symulowanego, odpowiedź predyktora jednokrokowego, zmierzoną odpowiedź rzeczywistego systemu oraz odpowiedź rzeczywistego systemu bez zakłócenia. Weryfikacja krzyżowa uzyskanego modelu czasu dyskretnego w warunkach praktycznych:
- (a) Może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y(n)$
 - (b) Może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y_0(n)$
 - (c) Może polegać na porównaniu odpowiedzi $y_m(n)$ z $y_0(n)$
 - (d) Może polegać na porównaniu odpowiedzi $y_m(n)$ z $y(n)$
 - (e) Jest najbardziej miarodajna, jeżeli wynika z porównania odpowiedzi $\hat{y}(n|n-1)$ z $y_0(n)$
 - (f) Nie zawsze jest miarodajna, jeżeli wynika z porównania odpowiedzi $\hat{y}(n|n-1)$ z $y(n)$
 - (g) Nie zawsze jest miarodajna, jeżeli wynika z porównania odpowiedzi $y_m(n)$ z $y(n)$

Wyjaśnienie:

Porównanie predyktora z odpowiedzią rzeczywistą systemu pozwala na ocenę jak dobrze model potrafi przewidywać rzeczywiste zachowanie systemu w kolejnym kroku czasowym, natomiast porównanie modelu symulowanego z rzeczywistą odpowiedzią systemu jest kluczowe aby sprawdzić czy model reprezentuje system w obecności różnych zakłóceń i dynamik systemu.

49. Zwiększenie liczby niezależnych parametrów w modelu:

- (a) Powinno być dobrze uzasadnione zgodnie z zasadą oszczędności modelu
- (b) Ułatwia przygotowanie i realizację eksperymentu identyfikacyjnego
- (c) Może prowadzić do zjawiska nadparametryzacji modelu i w konsekwencji do niskiej jakości estymacji parametrycznej
- (d) Zwiększa elastyczność modelu i tym samym zawsze skutkuje poprawą jakości wyznaczonego modelu

Wyjaśnienie:

Gdy zwiększamy liczbę parametrów to komplikuje się proces identyfikacji, ponieważ teraz trzeba zwiększać większą liczbę danych, to może prowadzić do nadparametryzacji modelu czyli tego że model ma zbyt wiele parametrów w stosunku do ilości dostępnych danych lub złożoności rzeczywistego systemu. Zasada oszczędności jest dla nas istotna w kontekście modeli więc warto jej przestrzegać, gdyż zwiększanie niezależnych parametrów może prowadzić do nadparametryzacji i przez to wariancje estymatorów mogą wzrosnąć – tego nie chcemy.

ustaw roboty (nie zostaw domyślnego czasu)
na drugą porcję

więcej lampki

ber	szkoleni
ber	homeseerena
ber	zestaw

delin delte

histeresa może być
z gotowym wys. intera
jeśli będzie wódr no intera to docho!
ADDER SCALER

funkcje logiczne

linearyzacja czujników
na początku

→ Device (opisy urządzeń)
→ Sensor definitions