


Politechnika Poznańska

Wydział Automatyki, Robotyki i Elektrotechniki



Identyfikacja systemów BAZA

3 czerwca 2025

1 Kocham Mateusz Gierdewicz

Oznaczenia kolorystyczne (z dedykacją dla daltonistów):

Zrobione, wiem o co chodzi

Zrobione, nie wiem o co chodzi

Cytat prof. dr hab. inż. Macieja Marcina Maurycego Michałka

Stan zrobienia zadań:

30/30

0/30

1. Model systemu rzeczywistego

- A. jest wykorzystywany głównie w obszarze nauki i techniki,
- B. może mieć moc wyjaśniającą naturę modelowanego procesu,
- C. zawsze jest wyrażany w języku matematyki w postaci stosownego równania,
- D. jest przybliżonym opisem systemu wynikającym z poczynionych założeń upraszczających.

1. Poprawne odpowiedzi:	B	D
-------------------------	---	---

ŻELAZNA REGUŁA – u Michałka odpowiedzi ze słowem *zawsze* są zawsze nieprawidłowe – natomiast z *może* najczęściej są poprawne. Model zawsze jest uproszczony: *Rzeczywistość zawsze jest bardziej skomplikowana.*

2. Identyfikacja systemu dynamicznego:

- A. polega na dopasowaniu modelu do danych eksperymentalnych,
- B. musi być przeprowadzana w zamkniętym układzie regulacji,
- C. wymaga znajomości praw fizyki determinujących odpowiedź systemu,
- D. wymaga znajomości lub pomiaru sygnału wejściowego i wyjściowego w identyfikowanym systemie.

2. Poprawne odpowiedzi:	A	D
-------------------------	---	---

C źle bo w BLACK-BOX nic nie wiemy i tak też można. B nieprawdziwe, preferujemy układ otwarty (więcej o tym w zadaniu 22). Reszta na logikę dobrze.

3. Model eksperymentalny:

- A. w warunkach praktycznych zawsze jest obciążony niepewnością modelowania,
- B. nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori,
- C. nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu jest znana a priori,
- D. nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori.

3. Poprawne odpowiedzi:	A	B
-------------------------	---	---

UWAGA - wyjątek od żelaznej reguły związanej ze słowem *zawsze*. Jeśli pytanie jest o to, czy są niedokładności, niepewności i tym podobne, to zawsze odpowiedź brzmi, że tak. Podejście GREY-BOX: znamy strukturę, szukamy parametrów, podejście BLACK-BOX: nie wiemy nic.


4. Procedura identyfikacji parametrycznej:

- A. może być w prosty sposób zautomatyzowana (nie wymaga ingerencji projektanta modelu),
- B. ma charakter iteracyjny, podobnie jak każdy proces projektowy,
- C. wykorzystuje dostępną wiedzę wstępną o identyfikowanym systemie,
- D. ogranicza się do wyznaczenia (estymacji) parametrów modelu.

4. Poprawne odpowiedzi:	B	C
-------------------------	---	---

D Źle, istnieją również nieparametryczne metody identyfikacji. (Prezentacja 1, str. 12):

Schemat iteracyjnej procedury identyfikacji systemu



Warunki konieczne pomyślnej identyfikacji:

- dostateczna wiedza wstępna (1)
- dostateczne pobudzenie systemu (2 i 3)
- właściwa akwizycja danych pomiarowych w (3)
- adekwatny zbiór modeli w (4)
- stosowne kryterium dopasowania w (5)
- dobre uwarunkowanie numeryczne obliczeń (6)


Akceptacja modelu użytkowego
zależy do celu jego wykorzystania.

5. Analiza korelacyjna:

- należy do nieparametrycznych metod identyfikacji systemów,
- wymaga znalezienia parametrycznego modelu identyfikowanego systemu dynamicznego,
- polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego,
- polega na oszacowaniu funkcji korelacji wzajemnej sygnału wyjściowego y z sygnałem wejściowym u systemu dynamicznego.

5. Poprawne odpowiedzi: **A** **C**

(str. 48) Bezpośrednim rezultatem analizy korelacyjnej jest skończony zbiór oszacowanych wartości $\hat{g}(i)$ próbek odpowiedzi impulsowej $g_o(i)$ identyfikowanego procesu. Jest to podrozdział książki o tytule *Nieparametryczne stochastyczne metody identyfikacji*.



Rysunek 1: (a) Odpowiedź skokowa pewnego liniowego systemu dynamicznego. (b) Wynik analizy widmowej pewnego systemu dynamicznego czasu ciągłego o transmitancji $G_o(s)$.

6. Wykres na rysunku 1(a) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu liniowego, przy czym skok pobudzenia o amplitudzie $A_u = 2$ podano w chwili $t = 0$. Na

podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że:

- A. w transmitancji systemu występuje człon opóźniający e^{-aT_0} , w którym $T_0 > 3$ s,
- B. wzmocnienie statyczne obiektu wynosi 0.5,
- C. transmitancja systemu posiada bieguny zespolone sprzężone,
- D. w transmitancji systemu występuje zero w prawej półpłaszczyźnie zespolonej.

6. Poprawne odpowiedzi:	A	D
--------------------------------	----------	----------

Na wykresie widać opóźnienie trwające 4 sekundy oraz podregulowanie, czyli zero w prawej półpłaszczyźnie. Wzmocnienie statyczne NIE WYNOSI 0.5 – to jest bait, spostrzegawczy student zauważy, że amplituda pobudzenia $A_u = 2$, więc wzmocnienie statyczne to 0.25 (nie ma jednostki).

7. Rysunek 1(b) ilustruje wynik analizy widmowej pewnego stabilnego i minimalnofazowego systemu $G_0(j\omega)$, uzyskany z wykorzystaniem dwóch estymatorów transmitancji:

$$\hat{G}_N^*(j\Omega_k) = \frac{Y_N(j\Omega_k)}{U_N(j\Omega_k)} \quad \text{oraz} \quad \hat{G}_N(j\Omega_k) = \frac{\hat{\Phi}_{yu}^s(j\Omega_k)}{\hat{\Phi}_{uu}^s(j\Omega_k)} \quad (1)$$

- A. wariancja estymatora $\hat{G}_N^*(j\Omega_k)$ jest większa niż wariancja estymatora $\hat{G}_N(j\Omega_k)$,
- B. transmitancja identyfikowanego systemu ma wyłącznie bieguny rzeczywiste,
- C. pasmo przenoszenia identyfikowanego systemu wynosi $[0; \omega_c]$, gdzie $\omega_c < 1$ rad/s,
- D. identyfikowany system posiada wzmocnienie statyczne $|k_0| \in [0; 1)$.

7. Poprawne odpowiedzi:	A	D
--------------------------------	----------	----------

Estymator $\hat{G}_N^*(j\Omega_k)$ to ten jaśniejszy, który bardziej szumi. Skoro bardziej szumi, to ma większą wariancję. Dla niskich pulsacji mamy w miarę stałą wartość, poniżej 0 dB, czyli wzmocnienie statyczne jest mniejsze niż 1. Ta wartość to poniżej -3 dB, więc to nie jest część pasma przenoszenia.

8. Dane jest równanie modelu systemu: $y^{(2)} + y^{(1)} + y^{p_1} = p_2 u$, gdzie p_1 i p_2 są szukanymi parametrami modelu, y jest sygnałem wyjściowym, a u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas:

- A. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := \ln y$ i $u^* := \ln u$,
- B. identyfikacja modelu charakterystyki statycznej systemu wymaga oszacowania sygnałów $y^{(2)}$ i $y^{(1)}$,
- C. model odwzorowania wejścia sterującego w wyjście w stanie ustalonym ma postać: $y^{p_1} = p_2 u$,
- D. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := y^{p_1}$ i $u^* := u$.

8. Poprawne odpowiedzi:	A	C
--------------------------------	----------	----------

W stanie ustalonym pochodne są zerowe, gdyż nic się nie zmienia. A więc odpowiedź C jest prawdziwa. Charakterystyka ma być statyczna, czyli znowu: interesuje nas stan ustalony, pochodne nie mają tam znaczenia. Odpowiedź B wykluczamy. D jest złe, gdyż jeden z parametrów nam zniknie w równaniu. Dowód na prawdziwość A:

$$\begin{aligned} y^* &:= \ln y \implies e^{y^*} = e^{\ln y} = y \\ u^* &:= \ln u \implies e^{u^*} = e^{\ln u} = u \\ y^{p_1} &= p_2 u \implies e^{p_1 y^*} = p_2 e^{u^*} \quad \rceil \quad \ln e^{p_1 y^*} = \ln p_2 e^{u^*} \\ p_1 y^* &= \ln(p_2 e^{u^*}) = \ln p_2 + u^* \\ y^* &= \frac{1}{p_1} u^* + \frac{\ln p_2}{p_1} \end{aligned} \quad (2)$$

$$\begin{aligned}
y(n) + ay(n-1)q^{-1} &= bu(n)q^{-3} + C(q^{-1})e(n) \\
y(n)(1+aq^{-1}) &= bu(n)q^{-3} + C(q^{-1})e(n) \\
y(n) &= \frac{bq^{-3}}{1+aq^{-1}} \cdot u(n) + \frac{C(q^{-1})}{1+aq^{-1}} \cdot e(n)
\end{aligned}$$

9. Jeżeli model systemu opisano równaniem $y(n) + ay(n-1) = bu(n-3) + C(q^{-1})e(n)$, gdzie $e(n)$ jest szumem białym, a $C(q^{-1})$ jest wielomianem operatora q^{-1} , wówczas:

- A. powyższy model należy do modelu typu ARMAX, jeżeli $C(q^{-1}) = 1$,
- B. przy zapisie regresyjnym dla $C(q^{-1}) = 1$ wektor regresji ma postać: $\varphi(n) = [-y(n-1) \ -u(n-3)]^T$,
- C. dynamiczny tor zakłócenia w systemie definiuje operator transmitancyjny: $H(q^{-1}) = \frac{C(q^{-1})}{1+aq^{-1}}$,
- D. dynamiczny tor zakłócenia w systemie definiuje operator transmitancyjny: $H(q^{-1}) = \frac{-bq^{-3}}{1+aq^{-1}}$

9. Poprawne odpowiedzi:	B	C
--------------------------------	----------	----------

Wzór na ARMAX w zadaniu 12, stąd C jest dobre. Aby otrzymać wektor regresji, wystarczy przetrzucić na prawą stronę wszystko poza $y(n)$, i już widać rozwiązanie.

10. System generujący dane pomiarowe ma postać: $y^{(2)}(t) + p_{1o}y^{(1)}(t) = p_{2o}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $u(t)$ oraz $y(t)$, wówczas model wyjaśniający dane pomiarowe spróbkowane z okresem $T_p > 0$:

- A. postaci $y(nT_p) = [-y^{(1)}(nT_p) \ u(nT_p)]p + v(nT_p)$ nie jest użyteczny w praktyce,
- B. postaci $y(nT_p) = [-y^{(1)}(nT_p) \ u(nT_p)]p + v(nT_p)$ zachowuje strukturę systemu czasu ciągłego,
- C. postaci $y(nT_p) = [-y(nT_p - T_p) \ u(nT_p)]p + v(nT_p)$ jest modelem czasu dyskretnego,
- D. wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego

10. Poprawne odpowiedzi:	A	B
---------------------------------	----------	----------

(str. 66) Postać regresyjną wyjścia możemy zapisać w wersji z sygnałami próbkowanymi z okresem próbkowania T_p :

$$\mathcal{Y}(nT_p) = [-\dot{\mathcal{Y}}(nT_p) \ \tau(nT_p)] \begin{bmatrix} J/b \\ 1/b \end{bmatrix} = \varphi^T T_p \mathbf{P}.$$

Jeżeli pomiarowo dostępne będzie tylko wejście sterujące τ i wyjście ω , to mimo poprawności powyższej regresji liniowej nie będziemy mogli jej bezpośrednio wykorzystać do celów identyfikacji ze względu na obecność w wektorze regresji pomiarowo niedostępnego sygnału $\dot{\mathcal{Y}} \equiv \dot{\omega}$ (tu: przyspieszenia kątownego wirnika). Taka regresja liniowa zatem nie spełnia reguły 3.2.

Pochodna wyjścia $y^{(1)}(nT_p)$ praktycznie nigdy nie jest dostępna pomiarowo, także w praktyce się nie przyda. Modele w odpowiedziach A, B, C nie są dyskretnie - nie zastosowano żadnej metody aproksymacji pochodnej. D to pytanie typowo michałkowe – filtry SVF to tylko jeden ze sposobów, ale można by też teoretycznie mierzyć prędkość i przyspieszenie.

11. System generujący dane pomiarowe ma postać: $y(n) = [y(n-1) \ y(n-2)]p_o + e(n)$, gdzie p_o jest wektorem parametrów prawdziwych, $v(n)$ jest szumem białym. Jeżeli symbolem $\hat{p}$ oznaczymy estymatę wektora parametrów modelu tego systemu, wówczas:

- A. odpowiedź optymalnego predyktora ma postać: $\hat{y}(n | n-1) = [y(n-1) \ y(n-2)]\hat{p}$,
- B. odpowiedź optymalnego predyktora ma postać: $\hat{y}(n | n-1) = [y(n-1) \ y(n-2)]p_o$,
- C. odpowiedź modelu symulowanego ma postać: $\hat{y}_m(n) = [\hat{y}_m(n-1) \ \hat{y}_m(n-2)]\hat{p}$,
- D. odpowiedź modelu symulowanego ma postać: $\hat{y}_m(n) = [y(n-1) \ y(n-2)]\hat{p}$

11. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Dla predyktora odrzucamy B, ponieważ pojawia się tam wektor parametrów prawdziwych (który nie jest znany). Dla modelu symulowanego prawdziwa jest odpowiedź C, bo model korzysta ze swoich poprzednich próbek, a nie z prawdziwej odpowiedzi.

$$y(n) = -y(n-1)q^{-1} + bq^{-2}u(n) + e(n) + cq^{-1}e(n)$$

12. Dany jest model czasu dyskretnego

$$y(n) = \frac{bq^{-2}}{1 + aq^{-1}}u(n) + \frac{1 + cq^{-1}}{1 + aq^{-1}}e(n), \quad (3)$$

gdzie $e(n)$ jest szumem białym, natomiast $a \neq 0$, $b \neq 0$ i $c \neq 0$ są parametrami modelu. Wówczas:

- A. model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2) \ e(n-1)]p + e(n)$, gdzie $p = [a \ b \ c]^T$,
- B. model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2)]p + v(n)$, przy czym $p = [a \ b]^T$ oraz $v(n) = e(n) + ce(n-1)$,
- C. model jest nieprzyczynowy ze względu na wejście u ,
- D. model jest typu ARX.

12. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Trzeba wymnożyć obustronnie przez mianownik. Otrzymujemy wtedy równanie:

$$y(n) = -aq^{-1}y(n) + bq^{-2}u(n) + cq^{-1}e(n) + e(n) \quad (4)$$

(str. 86) **Model ARX.** Postać modelu ARX wynika z następującego równania:

$$y(n) + a_1y(n-1) + \dots + a_ny(n-n_a) = b_1u(n-1) + \dots + b_nu(n-n_b) + e(n) \quad (5)$$

(str. 88) **Model ARMAX.** Istotne zwiększenie elastyczności modelu można uzyskać wprowadzając wielomian $C(q^{-1}, p)$ do licznika operatora transmitancyjnego H toru zakłócenia. (...) Równanie różnicowe prowadzące do modelu ARMAX ma postać:

$$\begin{aligned} y(n) + a_1y(n-1) + \dots + a_ny(n-n_a) = \\ = b_1u(n-1) + \dots + b_nu(n-n_b) + e(n) + c_1e(n-1) + \dots + c_n e(n-n_c) \end{aligned} \quad (6)$$

13. Estymator metody najmniejszych kwadratów błędów równaniowych (LS):

- A. znajduje zastosowanie tylko do modeli systemów liniowych,
- B. wynika z minimalizacji kryterium: $V_N \triangleq \frac{1}{2} \sum_{n=1}^N |y(n) - \hat{y}(n|n-1)|$
- C. przyjmuje jawną postać równania, gdy błąd równaniowy zależy liniowo od parametrów modelu,
- D. może prowadzić do obciążonych estymat parametrów modelu.

13. Poprawne odpowiedzi:

Liniowość faktycznie jest wymagana, ale nie chodzi o liniowość modelu, tylko o coś innego. Niech ktoś to znajdzie w książce bo mi się nie chce. B odpada bo w kryterium nie ma nic do kwadratu. D wyjaśnione w zadaniu 17.

14. Dane jest równanie estymatora $\hat{p}_N = (\Phi^T \Phi)^{-1} \Phi^T y$, gdzie Φ jest *stochastyczną* macierzą regresji (tj. elementy macierzy Φ zależą od stochastycznego zakłócenia v obecnego w równaniu $y = \varphi^T p + v$), a $N \gg \dim(\hat{p}_N)$ jest liczbą par $\{u_n, y_n\}_{n=1}^N$ danych pomiarowych. Wówczas:

- A. aby powyższy estymator był **zgodny**, zakłócenie stochastyczne v musi być szumem białym,
- B. powyższy estymator gwarantuje zbieżność $\hat{p}_N$ do parametrów prawdziwych p_o , jeżeli tylko $N \rightarrow \infty$,
- C. aby powyższy estymator był **zgodny**, struktura wektora regresji φ musi odpowiadać strukturze prawdziwego wektora φ_o systemu,
- D. powyższy estymator jest **nieobciążony**, jeżeli wartość oczekiwana zakłócenia v w równaniu regresyjnym $y = \varphi^T p + v$ jest zerowa.

14. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Zadanie na chłopski rozum. B odpada zgodnie z żelazną zasadą. C na logikę prawdziwą, jeśli mamy inną strukturę, to na pewno nie wyjdzie dobry wynik. Wybór A i D ponownie motywowany żelazną zasadą – w A to jest jeden z warunków, a w D warunek jest tylko jeden. Korzystając z rozeznania psychologicznego prowadzącego wybieramy odpowiedź A.

15. Znana jest struktura zidentyfikowanego systemu dynamicznego:

$$y(n) = \frac{b_o q^{-1}}{1 + a_o q^{-1}} u(n) + \frac{1 + c_o q^{-1}}{1 + a_o q^{-1}} e(n),$$

przy czym $e(n)$ jest szumem białym, a $a_o \neq 0$, $b_o \neq 0$ oraz c_o są nieznanymi parametrami prawdziwymi. Parametryczna identyfikacja systemu w układzie otwartym metodą najmniejszych kwadratów błędów równaniowych (LS):

- A. może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli $c_o = a_o$,
- B. gwarantuje zgodną estymację parametrów $p = [a \ b]^T$ modelu, gdy tylko $u(n)$ jest szumem białym,
- C. asymptotycznie (tj. dla liczby danych $N \rightarrow \infty$) prowadzi do statystycznie równoważnych wyników estymacji niezależnie czy stosujemy wersję wsadową LS czy rekursywną RLS,
- D. może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli $c_o = 0$.

15. Poprawne odpowiedzi:

(str. 123-124) Uzyskanie wyniku estymacji LS w postaci zamkniętego i bardzo prostego wzoru (4.11) było możliwe wskutek zapisania modelu (4.4) w postaci regresji liniowej (dzięki temu uzyskano błąd równaniowy (4.9) liniowo zależny od parametrów).

W przypadku modeli obiektów dynamicznych (procesów) *modele błędu równaniowego* spełniają bezpośrednio wymogi zapisu regresyjnego (4.4) i prowadzą do błędu równaniowego liniowo zależnego od parametrów p . Takim przypadkiem jest model ARX.

Uwaga 4.6. Liniowa zależność błędu równania (4.15) od parametrów p prowadzi do estymatora w postaci jawnej (4.11). W odróżnieniu od modelu ARX dla modelu ARMAX różnica ma charakter szumu kolorowego $Ce(n)$ zależnego od nieznanymi (szukanych) parametrów wielomianu C .

(str. 173) Estymator RLS jest inną formą estymatora LS ze wzoru (4.11), zatem asymptotycznie, tj. dla $N \rightarrow \infty$ i odpowiednio dużego N , estymator RLS (5.10)-(5.13) ma takie same własności statystyczne jak estymator wsadowy ze wzoru (4.11) – asymptotycznie twierdzenia 4.2 i 4.4 pozostają w mocy dla estymatora RLS.

Przypatrzmy się odpowiedzi B: *gwarantuje, gdy tylko* (czyli przy spełnieniu tylko jednego warunku). Stosujemy oczywiście żelazną zasadę i odrzucamy. Żeby w tym układzie LS dało zgodny estymator, model ma być ARX, czyli $c_o = 0$ (wzory na ARX i ARMAX w zadaniu 12).

16. Rzeczywisty system dynamiczny generujący dane pomiarowe ma postać $y = \varphi_o^T p_o + v$, gdzie φ_o oznacza prawdziwą strukturę wektora regresji, a p_o reprezentuje wektor prawdziwych parametrów systemu. Estymator LS zastosowany do modelu $y = \varphi^T p + v$ w celu parametrycznej identyfikacji systemu w układzie otwartym:

- A. może posiadać własność zgodności, jeżeli dane pomiarowe zawierają wystarczająco bogatą informację o systemie,
- B. zawsze zwraca estymaty $\hat{p}_N$ równe p_o (z prawdopodobieństwem 1), gdy liczba danych $N \rightarrow \infty$,
- C. może mieć własność zgodności, jeżeli model wyjaśniający dane $y = \varphi^T p + v$ będzie taki, że $\varphi = \varphi_o$ oraz v będzie szumem białym,
- D. będzie miał własność zgodności, jeżeli tylko v będzie szumem białym.

16. Poprawne odpowiedzi: A C

(Prezentacja 4, str. 19) Zakładając, że:

(z_1) Dane pomiarowe $Z^N = \{(u_n, y_n), n = 1, \dots, N\}$ są generowane przez obiekt rzeczywisty zgodnie z równaniem

$$y_n = \varphi_n^\top p_o + v_n \Rightarrow y = \Phi p_o + v,$$

gdzie p_o jest wektorem parametrów prawdziwych, a wektor regresji φ_n , o tej samej strukturze co w modelu (2), nie zależy od parametrów i nie zawiera zakłóceń stochastycznych (tzn. jest ustalony / deterministyczny),

(z_2) Zakłócenie $v_n \equiv e_n$ jest szumem białym o wariancji σ_v^2 .

Estymator $\hat{p}_N^{\text{LS}} = (\Phi^\top \Phi)^{-1} \Phi^\top y$ ze wzoru (6) ma następujące własności:

(w_1) Jest nieobciążony, tj. $\mathbb{E}[\hat{p}_N^{\text{LS}}] = p_o$,

(w_2) Macierz kowariancji estymatora jest określona wzorem

$$\text{Cov}[\hat{p}_N^{\text{LS}}] = P_N^{\text{LS}}, \quad P_N^{\text{LS}} = \sigma_v^2 (\Phi^\top \Phi)^{-1},$$

(w_3) $(\hat{p}_N^{\text{LS}} - p_o) \sim \mathcal{N}(0, P_N^{\text{LS}})$, gdy $v_n \equiv e_n$ ma rozkład normalny lub gdy $N \rightarrow \infty$.


B odpada zgodnie z żelazną zasadą. Estymaty są równe prawdziwym danym przy liczbie danych dążących do nieskończoności, (w_3), ale tylko przy spełnieniu obu założeń. Tak samo D potrzebuje spełnienia obu założeń – szum biały to tylko jedno z nich (z_2).

17. Parametryczna identyfikacja systemu $y = \varphi^T p_o + v$ w układzie otwartym metodą zmiennych instrumentalnych:

- A. zawsze daje lepsze wyniki estymacji parametrów niż te uzyskane metodą LS niezależnie od charakteru zakłócenia v ,
- B. pozwala na uzyskanie zgodnych estymat parametrów nawet, gdy zakłócenie v jest kolorowe,
- C. wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z zakłóceniem v ,
- D. wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z elementami wektora φ .

17. Poprawne odpowiedzi:	B	C
---------------------------------	----------	----------

(str. 162-164):



Rysunek 2: Zbiory estymat $\hat{p}_{N,j}$ dla $j = 1, \dots, 100$ uzyskane metodami LS („o”) oraz IV/LS („x”) dla stu zestawów danych z różnymi realizacjami zakłócenia v_2 ; średnia arytmetyczna ($m[\cdot]$) estymat wyznaczona na podstawie stu realizacji estymatora metody IV wynosi: $m[\hat{p}_N^{\text{IV}^c}] = [2.0127 \ 0.5071]^\top$; czarnym kwadratem zaznaczono parę prawdziwych parametrów procesu czasu ciągłego $p_o^c = [2.0 \ 0.5]^\top$

- Identyfikacja metodą LS błędów równaniowych dla zakłócenia białego daje estymaty parametrów (bliskie wartościom prawdziwym), dla których uzyskano najlepszą jakość modelu z punktu widzenia wartości funkcji V_m (metoda IV zasadniczo nie poprawia wyniku w tym przypadku).
- Zastosowanie estymatora LS metody błędów równaniowych dla zakłócenia kolorowego spowodowało obciążenie estymat i tym samym wyraźne pogorszenie zdolności predykcyjnych modelu.
- Pomimo obecności zakłócenia kolorowego zastosowanie metody IV pozwoliło na istotną poprawę jakości modelu dzięki teoretycznej zgodności estymatora IV stosującego instrumenty z nieskorelowane z zakłóceniem v .

A odpada zgodnie z żelazną zasadą o słowie *zawsze*.

18. Rekursywna metoda najmniejszych kwadratów wyznaczająca estymatę $\hat{p}(n)$:

- A. wynika z równania aktualizacji: $\hat{p}(n) = \hat{p}(n-1) + k\varepsilon(n)$, gdzie $k = \text{const}$,
- B. w wersji podstawowej skutkuje stopniową utratą zdolności adaptacyjnych estymatora, gdy $n \rightarrow \infty$,
- C. w wersji $\text{RLS}_{\lambda, \text{po}}$ zastosowaniu współczynnika zapominania $\lambda \in (0, 1)$ pozwala na śledzenie wolnozmiennych parametrów $p_o(n)$ systemu rzeczywistego,
- D. musi być wykonywana w trybie *on-line*, tj. w czasie rzeczywistym i równoległe do działającego systemu rzeczywistego.

18. Poprawne odpowiedzi:	B	C
--------------------------	---	---

(str. 178) Obie podstawowe metody RLS (w tym RELS) oraz RIV mają tę cechę, że wraz z postępem obliczeń w kolejnych iteracjach wzmocnienie

$$k_n = \hat{P}_n \varphi_n$$

jest zbieżne do zera i wygasa się zdolność estymatora do zmian estymat $\hat{p}_n$. W przypadku, gdy prawdziwe parametry procesu $p_o = \text{const.}$, jest to korzystna cecha. Jednak w wielu praktycznych przypadkach proces rzeczywisty ma zmienne w czasie parametry.

(str. 179) W przypadku zmiennych w czasie parametrów procesu rzeczywistego jesteśmy zainteresowani zachowaniem zdolności adaptacyjnych estymatorów rekurencyjnych, tak aby estymaty były w stanie śledzić zmiany parametrów $p_o(n)$ wraz z kontynuacją obliczeń rekurencyjnych. W tym celu wprowadza się jeden z trzech podstawowych mechanizmów do równań rekurencyjnych:

- M1: współczynnik zapominania $\lambda \in (0; 1)$, gdy zmiany $p_o(n)$ są wolne, ale permanentne (tzw. dryf parametrów),
- M2: formę estymatora Kalmana, gdy zmiany $p_o(n)$ są wolne, ale permanentne (tzw. błądzenie losowe parametrów),
- M3: resetowanie macierzy kowariancyjnej $\hat{P}_n$, gdy zmiany $p_o(n)$ są sporadyczne, ale gwałtowne (zmiany uderowe parametrów).

19. Metoda identyfikacji RELS:

- A. pozwala na estymację parametrów wielomianu $C(q^{-1})$ modelu ARMAX,
- B. jest zalecana w przypadku, gdy błąd równaniowy jest szumem białym,
- C. wykorzystuje opóźnione próbki błędu predykcji w wektorze regresji,
- D. jest dedykowana dla modelu ARX.

19. Poprawne odpowiedzi:	A	C
--------------------------	---	---

(str. 175) Gdy zakłócenie $v_n \equiv v(n)$ w równaniu (5.2) jest skorelowane ze zmiennymi regresyjnymi w wektorze φ i przyjmujemy, że zakłócenie to spełnia równanie

$$v(n) = C(q^{-1}, \mathbf{p})e(n),$$

gdzie C jest wielomianem monicznym, wówczas rozważane równanie (5.2) ma postać modelu AR-MAX, którego parametry możemy estymować, stosując rozszerzoną metodę LS (czyli ELS). Z podrozdziału 4.4.2 wiemy, że model

$$Ay(n) = Bu(n) + Ce(n),$$

o stopniach wielomianów n_a , n_b i n_c , można zapisać w postaci regresyjnej (5.2) z zakłóceniem w postaci szumu białego, gdzie

$$\varphi^\top \triangleq [-y(n-1) \dots y(n-n_a) \quad u(n-1) \dots u(n-n_b) \quad \hat{e}(n-1) \dots \hat{e}(n-n_c)].$$

20. Adaptacyjna identyfikacja zmiennych parametrów $p_o(n)$ systemu rzeczywistego metodą RLS z wykorzystaniem mechanizmu resetowania macierzy kowariancyjnej $P(n)$:

- A. polega na zerowaniu macierzy $P(n)$ w chwili wykrycia zmian parametrów systemu,
- B. polega na wymuszeniu w przyjętym modelu losowych lecz ustalonych zmian parametrów $p_o(n)$,
- C. może skutkować nagłą zmianą estymat parametrów modelu zaraz po resecie macierzy $P(n)$,
- D. polega na podstawieniu pod $P(n)$ wybranej macierzy dodatnio określonej.

20. Poprawne odpowiedzi:	C	D
---------------------------------	----------	----------

(str. 187) Resetowanie polega na nadpisaniu bieżącej macierzy $\bar{P}_n$ dodatnio określoną macierzą diagonalną (podobnie jak robimy to w przypadku wyboru początkowego $\bar{P}_0$), aby tymczasowo odzyskać zdolności adaptacyjne estymatora. Należy jednak pamiętać, że skutkiem ubocznym zresetowania macierzy kowariancyjnej jest nagła zmiana i wzrost fluktuacji estymat $\hat{p}_n$.

21. Dany jest system rzeczywisty $y(n) = [y(n-1) \ u(n-2)]^T p_o + v(n)$, z którego zebrano dane pomiarowe $Z^N = \{y(n), u(n)\}_{n=0}^N$ i wyznaczono obciążone estymaty $\hat{p}^{LS} = [\hat{p}_1^{LS} \ \hat{p}_2^{LS}]^T$ modelu o tej samej strukturze wektora regresji. Stosując metodę identyfikacji typu RIV zmienne instrumentalne:

- A. można wybrać następująco: $x \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n-1) = [y(n-2) \ u(n-3)]\hat{p}^{IV}(n-1)$,
- B. można wybrać następująco: $x \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n-1) = [x(n-2) \ u(n-3)]\hat{p}^{LS}$,
- C. można wybrać następująco: $x \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n) = [x(n-1) \ u(n-2)]\hat{p}^{IV}(n-1)$,
- D. można wybrać następująco: $x \triangleq [x(n-1) \ u(n-2)]^T$, gdzie $x(n) = [y(n-1) \ u(n-2)]\hat{p}^{LS}$.

21. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Tylko w A i C wektor parametrów jest prawidłowo oznaczony jako $\hat{p}^{IV}$.

22. Identyfikacja obiektu objętego ujemnym sprzężeniem zwrotnym w układzie regulacji z konwencjonalnym liniowym regulatorem o stałych parametrach:

- A. jest zalecana ze względu na gwarancję nieustannego pobudzania systemu sygnałem sterującym,
- B. zwykle daje lepsze wyniki niż identyfikacja w układzie otwartym,
- C. może prowadzić do niejednoznacznej estymacji parametrów modelu ze względu na zależność sygnału wejściowego obiektu od jego odpowiedzi,
- D. może być konieczna, aby zapewnić ograniczoną odpowiedź identyfikowanego obiektu.


22. Poprawne odpowiedzi:	C	D
---------------------------------	----------	----------

(str. 224) Zasadniczo zaleca się, aby identyfikację obiektów wykonywać w torze otwartym, intencjonalnie projektując wejściowy sygnał pobudzający u zapewniający nieustanne pobudzenie wystarczająco dużego rzędu (w przypadku czynnego eksperymentu identyfikacyjnego). Jednak w pewnych sytuacjach identyfikacja musi odbywać się podczas pracy obiektu w układzie sterowania ze sprzężeniem zwrotnym. Przyczynami takich sytuacji są:

- niestabilność dynamiki identyfikowanego procesu wymagająca wstępnej stabilizacji w układzie regulacji,
- konieczność zapewnienia odpowiedzi obiektu w ograniczonym i bezpiecznym zakresie warunków pracy,
- konieczność biernej (pasywnej) identyfikacji obiektu pracującego w układzie regulacji w ramach działającego ciągu technologicznego,
- działanie obiektu w układzie sterowania adaptacyjnego wykorzystującego aktualne estymaty parametrów modelu do przestrajania regulatora.

Na podstawie fragmentu odpadają A i B, potwierdzone jest D. Potwierdzenie C można znaleźć w Przykładzie 6.1 na stronie 227.

23. Wykres na rysunku 3 przedstawia gęstość widmową mocy zaprojektowanego sygnału pobudzającego $u(n)$ typu GBN w funkcji pulsacji unormowanej. Na podstawie wykresu można stwierdzić, że:



Rysunek 3: Gęstość widmowa mocy Φ_{GBN} sygnału pobudzającego $u(n)$ typu GBN

- A. sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{ks}{1+sT}$, $T > 0$,
 B. sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{1}{1+sT}$, $T > 0$,
 C. sygnał ten jest nieustannie pobudzający rzędu $\delta_u < 4$,
 D. sygnał ten jest nieustannie pobudzający rzędu $\delta_u > 12$.

23. Poprawne odpowiedzi:	B	D
---------------------------------	----------	----------

(str. 216) **Reguła 6.3.** Jeżeli wejściowy sygnał $u(n)$ jest nieustannie pobudzającym rzędu $\delta_u > 0$ (wg definicji 6.2), to jego gęstość widmowa mocy $\Phi_{uu}(\Omega_k)$ jest dodatnia w δ_u punktach dla pulsacji $\Omega_k \in [0; 2\pi)$.

Dla sygnałów skalarnych zachodzi także implikacja odwrotna do tej z reguły 6.3, tj. jeżeli gęstość widmowa mocy $\Phi_{uu}(\Omega_k)$ jest dodatnia dokładnie w δ_u punktach dla pulsacji $\Omega_k \in [0; 2\pi)$, to sygnał $u(n)$ jest nieustannie pobudzającym rzędu δ_u .

Było już zadanie polegające na łączeniu kropek (patrz dodatek A), teraz idziemy krok dalej – tutaj musimy policzyć kropki.

24. Wybór okresu próbkowania $T_p > 0$ sygnałów $u(t)$ oraz $y(t)$ do celów parametrycznej identyfikacji modelu czasu dyskretnego:

- A. jest właściwy, jeżeli $T_p \approx T/10$, gdzie $T > 0$ jest dominującą stałą czasową systemu ciągłego,
- B. generalnie jest tym lepszy, im mniejsza wartość T_p ,
- C. nie ma wpływu na jakość identyfikacji, gdy tylko spełnia twierdzenie o próbkowaniu,
- D. sugeruje mniejsze wartości T_p , gdy model ma być lepiej dopasowany w zakresie wyższych częstotliwości.

24. Poprawne odpowiedzi:	A	D
--------------------------	---	---

(str. 79):

- Przy identyfikacji parametrycznej modeli czasu ciągłego z danych próbkowanych dobór czasu próbkowania T_p jest bardzo prosty i intuicyjny – okres T_p wybiera się zwykle jako możliwie najkrótszy (w praktyce: rozsądnie krótki) i może on być zmienny w czasie.
- Przy identyfikacji parametrycznej modeli czasu dyskretnego zbyt krótki okres próbkowania T_p sygnałów może prowadzić do problemów numerycznych wyznaczania estymat parametrów (oczywiście zbyt długi okres próbkowania także pogarsza jakość modelu); zatem wybór okresu próbkowania przy podejściu pośrednim jest krytyczny oraz nieintuicyjny i powinien wynikać z wiedzy wstępnej o paśmie przenoszenia oryginalnego procesu.

Na tej podstawie można odrzucić odpowiedzi B i C.

25. Rząd δ_u nieustannego pobudzenia sygnału $u(n)$ stosowanego podczas eksperymentu identyfikacyjnego:

- A. nie ma wpływu na zbieżność estymat parametrów modelu przy identyfikacji metodą RIV,
- B. jest związany z liczbą składowych częstotliwościowych zawartych w sygnale $u(n)$,
- C. powinien być taki, że $\delta_u \geq \dim(p)$, gdzie p jest wektorem parametrów modelu toru sterowania,
- D. jest równy 2, gdy ma on postać sumy dwóch składowych sinusoidalnych o różnych pulsacjach.

25. Poprawne odpowiedzi:	B	C
--------------------------	---	---

(str. 215-216) Stosując definicję 6.2, można ściśle określić rząd δ_u nieustannego pobudzenia dla pewnych typowych sygnałów pobudzających, mianowicie (parafrazuję):

- sygnał typu szum biały o wariancji σ^2 : dowolnie duży rząd δ_u ,
- sygnał skokowy o amplitudzie skoku $A \neq 0$: $\delta_u = 1$,
- sygnał typu delta Kroneckera (impuls jednostkowy): nie jest nieustannie pobudzający,
- sygnał sinusoidalny: $\delta_u = 2$.

Rząd δ_u nieustannego pobudzenia sygnału $u(n)$ jest związany z jego gęstością widmową mocy $\Phi_{uu}(\Omega_k)$, tj. z jego właściwościami częstotliwościowymi.

(str. 216) **Reguła 6.4.** Rozważmy zbiór modeli

$$\mathcal{M}(p) : \quad y(n) = G(q^{-1}, p)u(n) + v(n) = \frac{B(q^{-1}, p)}{A(q^{-1}, p)}u(n) + v(n),$$

gdzie p , $d_p \triangleq \dim(p) = n_b + n_a$ jest wektorem parametrów względem pierwszych wielomianów A i B operatora $G(q^{-1}, p)$, a $v(n)$ jest zakłóceniem stochastycznym. Eksperyment identyfikacyjny realizowany w układzie otwartym z wykorzystaniem sygnału $u(n)$ o rzędzie nieustannego pobudzenia

$$\delta_u \geq d_p = n_a + n_b$$

jest wystarczająco informatywny (wystarczająco bogaty w informację dla liczby danych $N \rightarrow \infty$) w odniesieniu do zbioru modeli $\mathcal{M}(p)$. W skrócie, rząd δ_u ma być nie mniejszy niż ilość estymowanych parametrów d_p . Jakby dodać dwa sinusy, to $2 + 2 = 4$, także D odpada.

26. Współczynnik szczytu C_r sygnału pobudzającego $u(n)$:

- A. zaleca się, aby był jak największy podczas eksperymentu identyfikacyjnego,
- B. ma wartość $C_r = 0.5$, gdy $u(n)$ jest sygnałem typu suma sinusów,
- C. ma wartość $C_r = 1$, gdy $u(n)$ jest sygnałem typu PRBS,
- D. zaleca się, aby był jak najmniejszy podczas eksperymentu identyfikacyjnego.

26. Poprawne odpowiedzi:	C	D
--------------------------	---	---

(str. 217) Pożądanymi cechami sygnałów pobudzających projektowanych do celów identyfikacji w układzie otwartym są:

- (c1) prostota kształtowania gęstości widmowej mocy $\Phi_{uu}(\Omega_k)$ – umożliwia spełnienie reguły 6.2,
- (c2) ściśle ograniczona amplituda: $\forall n > 0 \quad |u(n)| \leq \bar{u}$, przy czym ograniczenie $\bar{u} > 0$ jest narzucone przez projektanta (narzucenie ograniczenia na amplitudę sygnału pobudzającego wpływa na: bezpieczeństwo pracy procesu, zachowanie liniowego zakresu działania identyfikowanego procesu i układów wykonawczych, względy ekonomiczne – koszt eksperymentu),
- (c3) mała wartość tzw. *współczynnika szczytu* (ang. *crest factor*), zdefiniowanego dla sygnału $u(n)$ o zerowej wartości średniej jako:

$$C_r \triangleq \sqrt{\frac{\max_{n \geq 0} u^2(n)}{\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=0}^{N-1} u^2(n)}} = \sqrt{\frac{\text{maksimum kwadratu amplitudy}}{\text{moc niesiona przez sygnał}}}; \quad (7)$$

Minimalizacja współczynnika C_r skutkuje relatywnie dużą mocą niesioną przez sygnał $u(n)$ (co jest korzystne), bo pozwala na zwiększenie precyzji estymacji parametrycznej modelu przy jednoczesnym ograniczeniu jego amplitudy. Ten parametr nie może mieć wartości mniejszej niż 1, bo wtedy moc przekroczyłaby kwadrat amplitudy - efektywność sygnału by przekroczyła 100%, co nie jest możliwe.

27. Zebrano niezależnie dwa zbiory Z_1 i Z_2 próbek sygnału wejściowego i wyjściowego pewnego systemu. Przeprowadzono identyfikację parametru p modelu tego systemu niezależnie dla obu zbiorów danych uzyskując estymaty: $\hat{p}_1$ (na podstawie zbioru Z_1) oraz $\hat{p}_2$ (na podstawie zbioru Z_2). Obliczono wartości wariancji v_1 i v_2 dla poszczególnych estymat. Optymalną (w sensie minimum wariancji) wypadkową estymatę $\hat{p}$ parametru p oraz odpowiadającą jej wartość wariancji v uzyskamy, gdy:

- A. $\hat{p} = (v_2 \hat{p}_1 + v_1 \hat{p}_2) / (v_1 + v_2)$,
- B. $\hat{p} = (\hat{p}_1 + \hat{p}_2) / (v_1 + v_2)$,
- C. $v = (v_1 + v_2) / 2$,
- D. $v = v_1 v_2 / (v_1 + v_2)$

27. Poprawne odpowiedzi:	A	D
--------------------------	---	---

(str. 241) Optymalny (w sensie minimum wariancji) sposób łączenia estymat dla m bloków danych wynika z następującej formuły:

$$\hat{p} = P \sum_{i=1}^m P_{N_i}^{-1} \hat{p}_{N_i}, \quad \text{gdzie} \quad P \triangleq \left(\sum_{i=1}^m P_{N_i}^{-1} \right)^{-1}, \quad (8)$$

natomiast $\hat{p}_{N_i}$ oraz P_{N_i} , $i = 1, \dots, m$, są odpowiednio wektorem estymat oraz macierzą kowariancji obliczonymi dla i -tego bloku danych. Macierz P jest macierzą kowariancji wypadkowego wektora estymat $\hat{p}$.

Interpretacja wzoru jest bardzo czytelna dla skalarnych estymat $\hat{p}_{N_i}$ (uzyskanych z użyciem estymatorów nieobciążonych) i odpowiadających im wariancji P_{N_i} dla konkretnej liczby zbiorów, np. $i = 1, 2, 3$. Mianowicie wypadkowa estymata i odpowiadająca jej wypadkowa wariancja w tym przypadku wynoszą:

$$\hat{p} = \frac{\hat{p}_1 P_{N_1}^{-1} + \hat{p}_2 P_{N_2}^{-1} + \hat{p}_3 P_{N_3}^{-1}}{P_{N_1}^{-1} + P_{N_2}^{-1} + P_{N_3}^{-1}}, \quad P = \frac{1}{P_{N_1}^{-1} + P_{N_2}^{-1} + P_{N_3}^{-1}}. \quad (9)$$

Zatem estymata $\hat{p}$ jest liniową kombinacją estymat składowych ważonych z tym mniejszymi wagami, im większe są odpowiadające im wariancje. Podstawiając nasze dane do równań 9, otrzymujemy (u nas wariancje to skalary a nie macierze):

$$\hat{p} = \frac{\hat{p}_1 v_1^{-1} + \hat{p}_2 v_2^{-1}}{v_1^{-1} + v_2^{-1}}, \quad v = \frac{1}{v_1^{-1} + v_2^{-1}}. \quad (10)$$

Wystarczy wymnożyć obie strony ułamka przez $(v_1 v_2)$.

$$\hat{p} = \frac{\hat{p}_1 v_2 + \hat{p}_2 v_1}{v_1 + v_2}, \quad v = \frac{v_1 v_2}{v_1 + v_2}. \quad (11)$$

28. Weryfikacja wyznaczonego modelu parametrycznego:

- A. w praktyce polega na porównaniu obliczonych estymat $\hat{p}_N$ z prawdziwymi parametrami p_o systemu,
- B. dotyczy elastyczności, oszczędności i użyteczności modelu w danym zastosowaniu,
- C. powinna sugerować wybór najoszczędniejszego modelu spośród wszystkich akceptowalnych modeli,
- D. powinna być wykonywana z wykorzystaniem danych użytych do estymacji parametrów modelu.

28. Poprawne odpowiedzi:	B	C
---------------------------------	----------	----------

Prawdziwe parametry systemu nie są znane, nie można z nimi porównać, weryfikację przeprowadza się dla innych danych niż identyfikację.

29. Niech $y_m(n)$, $\hat{y}(n|n-1)$, $y(n)$ oraz $y_o(n)$ oznaczają, odpowiednio, odpowiedź modelu symulowanego, odpowiedź predyktora jednokrokowego, zmierzona odpowiedź rzeczywistego systemu oraz odpowiedź rzeczywistego systemu bez zakłócenia. Weryfikacja krzyżowa uzyskanego modelu czasu dyskretnego w warunkach praktycznych:

- A. może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y(n)$,
- B. może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y_o(n)$,
- C. może polegać na porównaniu odpowiedzi $y_m(n)$ z $y_o(n)$,
- D. może polegać na porównaniu odpowiedzi $y_m(n)$ z $y(n)$.

29. Poprawne odpowiedzi:	A	D
---------------------------------	----------	----------

Odpowiedź bez zakłócenia nigdy nie jest dostępna w warunkach praktycznych – odrzucamy odpowiedzi, w których się pojawia.

30. Zwiększanie liczby niezależnych parametrów w modelu:

- A. powinno być dobrze uzasadnione zgodnie z zasadą oszczędności modelu,

- B. ułatwia przygotowanie i realizację eksperymentu identyfikacyjnego,
- C. może prowadzić do zjawiska nadparametryzacji modelu i w konsekwencji do niskiej jakości estymacji parametrycznej,
- D. zwiększa elastyczność modelu i tym samym zawsze skutkuje poprawą jakości wyznaczonego modelu.

30. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Przy zbyt dużej ilości parametrów robi się dopasowanie do szumów z konkretnego zbioru danych. Stosujemy najmniejszą ilość parametrów, która daje satysfakcjonujące wyniki (jest to zasada oszczędności modelu).

2 Baza z Norymbergi

Spora część zadań w tej bazie się pokrywa z tymi na powyżej. Przykładowo trzy pierwsze zadania mają to samo polecenie co zadanie 2 z bazy KMG. Różnią się trochę odpowiedziami. Nie widzę potrzeby objaśniania wszystkich tych pytań, może dodam wyjaśnienia do jakichś wybranych. Na pewno dodam objaśnienia to tych, gdzie nie zgadzam się z odpowiedziami. Jeśli jest konflikt między odpowiedziami, to polecam pójść za wersją z bazy Kocham Mateusz Gierdewicz.

Przy nauce wszystkie pytania o sterowanie, regulatory (np. 16. – 25.) można pominąć; nie ma ich w naszym zakresie materiału.

32. Dane jest równanie modelu systemu: $y^{(2)} + y^{(1)} + y^{p_1} = p_2 u$, gdzie p_1 i p_2 są szukanymi parametrami modelu, y jest sygnałem wyjściowym, a u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas:

- A. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := \ln y$ i $u^* := \ln u$,
- B. identyfikacja modelu charakterystyki statycznej systemu wymaga oszacowania sygnałów $y^{(2)}$ i $y^{(1)}$,
- C. model odwzorowania wejścia sterującego w wyjście w stanie ustalonym ma postać: $y^{p_1} = p_2 u$,
- D. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zamiany zmiennych $y^* := y^{p_1}$ i $u^* := u$.

32. Poprawne odpowiedzi:	A	C
---------------------------------	----------	----------

Zadanie 8 w bazie KMG.

51. System generujący dane pomiarowe ma postać: $y^{(2)}(t) + p_{1o}y^{(1)}(t) = p_{2o}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $u(t)$ oraz $y(t)$, wówczas model wyjaśniający dane pomiarowe spróbkowane z okresem $T_p > 0$:

- A. postaci $y(nT_p) = [-y^{(1)}(nT_p) \ u(nT_p)]p + v(nT_p)$ nie jest użyteczny w praktyce,
- B. postaci $y(nT_p) = [-y^{(1)}(nT_p) \ u(nT_p)]p + v(nT_p)$ zachowuje strukturę systemu czasu ciągłego,
- C. postaci $y(nT_p) = [-y(nT_p - T_p) \ u(nT_p)]p + v(nT_p)$ jest modelem czasu dyskretnego,
- D. wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego

51. Poprawne odpowiedzi:	A	B
---------------------------------	----------	----------

Zadanie 10 w bazie KMG.

52. System generujący dane pomiarowe ma postać: $y^{(2)}(t) + p_{1o}y^{(1)}(t) + p_{3o}y(t) = p_{2o}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $u(t)$ oraz $y(t)$, wówczas model

$$y^{(2)}(nT_p) = [-y^{(1)}(nT_p) \quad -y(nT_p) \quad u(nT_p)]p + v(nT_p) \quad (12)$$

wyjaśniający dane pomiarowe spróbkowane z okresem $T_p > 0$:

- A. jest modelem czasu dyskretnego,
- B. zachowuje oryginalną strukturę systemu czasu ciągłego,
- C. wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego,
- D. wymaga zastosowania filtrów SVF, jeżeli ma być użyty do estymacji metodą LS parametrów p .

52. Poprawne odpowiedzi:	B	D
---------------------------------	----------	----------

W mocy pozostaje wyjaśnienie z zadania 10 w bazie KMG. Podany model nie jest czasu dyskretnego, pomimo tego, że jest spróbkowany. Pochodna nie jest aproksymowana, więc dalej jesteśmy w czasie ciągłym.

58. Wykres na rysunku 1(a) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu liniowego o transmitancji ściśle właściwej, przy czym skok pobudzenia o amplitudzie $A_u = 10$ podano w chwili $t = 2$. Na podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że:

- A. w transmitancji systemu występuje człon opóźniający e^{-aT_0} , w którym $T_0 > 3$ s,
- B. wzmocnienie statyczne obiektu wynosi 0.5,
- C. transmitancja systemu posiada przynajmniej dwa bieguny rzeczywiste,
- D. w transmitancji systemu występuje dodatnie zero.

58. Poprawne odpowiedzi:	C	D
---------------------------------	----------	----------

Podobne do zadania 6 w bazie KMG. Na wykresie widać opóźnienie trwające 4 sekundy oraz podregulowanie, czyli zero w prawej półpłaszczyźnie. Wzmocnienie statyczne NIE WYNOSI 0.5 – to jest bait, spostrzegawczy student zauważy, że amplituda pobudzenia $A_u = 10$, więc wzmocnienie statyczne to 0.05 (nie ma jednostki). Koledzy, którzy robili tą drugą bazę, dali się nabrać na najprostszy michałkowy bait. Oczywiście czas opóźnienia nie wynosi więcej niż 3 sekundy, bo sygnał podano w chwili $t = 2$ [s]. C – start odpowiedzi jest łagodny. Dla inercji pierwszego rzędu start wykresu jest gwałtowny. Nie ma oscylacji, stąd bieguny rzeczywiste. D – podregulowanie, czyli zero w prawej półpłaszczyźnie.

63. Estymator metody najmniejszych kwadratów błędów równaniowych (LS):

- A. znajduje zastosowanie tylko do modeli systemów liniowych statycznych,
- B. wynika z minimalizacji kryterium: $V_N \triangleq \frac{1}{2} \sum_{n=1}^N |y^2(n) - \hat{y}^2(n|n-1)|$
- C. przyjmuje jawną postać równania, gdy błąd równaniowy zależy liniowo od parametrów modelu,
- D. może być obciążony lub nieobciążony w zależności od charakteru zakłócenia występującego w równaniu regresji liniowej.

63. Poprawne odpowiedzi:	C	D
---------------------------------	----------	----------

Podobne do zadania 13 w bazie KMG. Minimalizowana funkcja ma postać (str. 120):

$$V_N \triangleq \sum_{n=1}^N (\mathcal{Y}_n - \varphi_n^T p)^2. \quad (13)$$

Czyli najpierw liczymy błąd, a potem podnosimy do kwadratu. W odpowiedzi B jest to zrobione w odwrotnej kolejności. Odpowiedź D jest bardzo myląca – może być, a może nie być.

odp poprawna;

odp niepoprawna;

powtarzające się pytanie(buło na 1 terminie)

xxx - do do

1. **Identyfikacja systemu dynamicznego: (A, D)**
 - A. Polega na dopasowaniu modelu do danych eksperymentalnych
 - B. Polega na znalezieniu rzeczywistych wartości parametrów modelu systemu
 - C. Wymaga znajomości praw fizycznych determinujących odpowiedź systemu
 - D. Wymaga przeprowadzenia eksperymentu na systemie rzeczywistym
2. **Identyfikacja systemu dynamicznego (A, D)**
 - A. polega na dopasowywaniu modelu do danych eksperymentalnych
 - B. musi być przeprowadzona w zamkniętym układzie regulacji
 - C. wymaga znajomości praw fizyki determinujących odpowiedź systemu
 - D. wymaga znajomości lub pomiaru sygnału wejściowego u i wyjściowego y identyfikowanego systemu
3. **Identyfikacja systemu dynamicznego (A, B)**
 - A. polega na dopasowaniu modelu matematycznego do danych eksperymentalnych
 - B. wymaga znajomości lub pomiaru sygnału wejściowego u i wyjściowego y identyfikowanego systemu
 - C. jest tożsama z analitycznym modelowaniem systemu dynamicznego
 - D. wymaga znajomości praw fizyki determinujących odpowiedź systemu na dane pobudzenie
4. **Podczas procedury identyfikacji systemu: (A, D)**
 - A. Należy pobudzać sygnałem wejściowym o dostatecznie bogatym spektrum częstotliwościowym
 - B. Rząd przyjętej struktury modelu nie ma wpływu na jakość identyfikacji
 - C. Etap weryfikacji modelu powinien być realizowany w oparciu o dane użyte do estymacji parametrów
 - D. Etap weryfikacji modelu powinien być realizowany w oparciu o inne dane niż te użyte podczas etapu estymacji parametrów
5. **Identyfikacja obiektu w zamkniętym układzie regulacji (C, D)**
 - A. Wymaga pomiaru sygnału wyjściowego oraz sygnału zadanego
 - B. Zwykle daje lepsze wyniki niż identyfikacja w torze otwartym
 - C. Może prowadzić do obciążenia estymat parametrów modelu ze względu na zależność sygnału wejściowego obiektu od sygnału wyjściowego
 - D. Może być konieczna aby zapewnić ograniczoną odpowiedź obiektu regulacji
6. **Rząd trwałego pobudzenia PE(u) sygnału wejściowego $u(n)$: (A, D)**
 - A. Jest dowolny gdy $u(n)$ jest szumem białym
 - B. Nie ma wpływu na zbieżność estymat parametrów modelu
 - C. Jest równy 2 gdy ma on postać funkcji impulsowej
 - D. Jest równy 2 gdy ma on postać funkcji sinusoidalnej
7. **Metoda identyfikacji najmniejszych kwadratów: (C, D)**
 - A. Znajduje zastosowanie tylko do modeli systemów liniowych
 - B. Wynika z minimalizacji kryterium
$$V_N = \frac{1}{2} \sum_{i=1}^N |y(i) - \hat{y}(i)|$$
 - C. Korzysta z liniowej parametryzacji modelu systemu
 - D. Może prowadzić do nieobciążonych estymatorów parametrów modelu

odp poprawna; odp niepoprawna; powtarzające się pytanie(było na 1 terminie)
xxx - do do

1. Identyfikacja systemu dynamicznego: (A, D)

- A. Polega na dopasowaniu modelu do danych eksperymentalnych
- B. Polega na znalezieniu rzeczywistych wartości parametrów modelu systemu
- C. Wymaga znajomości praw fizycznych determinujących odpowiedź systemu
- D. Wymaga przeprowadzenia eksperymentu na systemie rzeczywistym

2. Identyfikacja systemu dynamicznego (A, D)

- A. polega na dopasowywaniu modelu do danych eksperymentalnych
- B. musi być przeprowadzona w zamkniętym układzie regulacji
- C. wymaga znajomości praw fizyki determinujących odpowiedź systemu
- D. wymaga znajomości lub pomiaru sygnału wejściowego u i wyjściowego y identyfikowanego systemu

3. Identyfikacja systemu dynamicznego (A, B)

- A. polega na dopasowaniu modelu matematycznego do danych eksperymentalnych
- B. wymaga znajomości lub pomiaru sygnału wejściowego u i wyjściowego y identyfikowanego systemu
- C. jest tożsama z analitycznym modelowaniem systemu dynamicznego
- D. wymaga znajomości praw fizyki determinujących odpowiedź systemu na dane pobudzenie

4. Podczas procedury identyfikacji systemu: (A, D)

- A. Należy pobudzać sygnałem wejściowym o dostatecznie bogatym spektrum częstotliwościowym
- B. Rząd przyjętej struktury modelu nie ma wpływu na jakość identyfikacji
- C. Etap weryfikacji modelu powinien być realizowany w oparciu o dane użyte do estymacji parametrów
- D. Etap weryfikacji modelu powinien być realizowany w oparciu o inne dane niż te użyte podczas etapu estymacji parametrów

5. Identyfikacja obiektu w zamkniętym układzie regulacji (C, D)

- A. Wymaga pomiaru sygnału wyjściowego oraz sygnału zadanego
- B. Zwykle daje lepsze wyniki niż identyfikacja w torze otwartym
- C. Może prowadzić do obciążenia estymat parametrów modelu ze względu na zależność sygnału wejściowego obiektu od sygnału wyjściowego
- D. Może być konieczna aby zapewnić ograniczoną odpowiedź obiektu regulacji

6. Rząd trwałego pobudzenia $PE(u)$ sygnału wejściowego $u(n)$: (A, D)

- A. Jest dowolny gdy $u(n)$ jest szumem białym
- B. Nie ma wpływu na zbieżność estymat parametrów modelu
- C. Jest równy 2 gdy ma on postać funkcji impulsowej
- D. Jest równy 2 gdy ma on postać funkcji sinusoidalnej

7. Metoda identyfikacji najmniejszych kwadratów: (C, D)

- A. Znajduje zastosowanie tylko do modeli systemów liniowych
- B. Wynika z minimalizacji kryterium
- C. Korzysta z liniowej parametryzacji modelu systemu
- D. Może prowadzić do nieobciążonych estymatorów parametrów modelu

8. Równanie $\hat{p}_{LS} = (\Phi^T \Phi)^{-1} \Phi^T y$: (A, B)
- A. Określa optymalny wektor parametrów wsadowej metody najmniejszych kwadratów

B. Jest tożsame z $\hat{p}_{LS} = \Phi^- y$ gdzie Φ^- jest pseudo-odwrotnością lewostronną

C. Jest tożsame z $\hat{p}_{LS} = \Phi^+ y$ gdzie Φ^+ jest pseudo-odwrotnością prawostronną

D. Określa estymator parametrów rekurencyjnej metody najmniejszych kwadratów

9. W równaniu $\hat{y}(n) = \varphi^T(n) \hat{p} + v(n)$: (B, C)

A. $v(n) = C(q^{-1})\varepsilon(n)$ reprezentuje szum biały

B. $\varphi^T(n)$ reprezentuje wektor zmiennych regresji

C. Składowymi wektora regresji mogą być opóźnione w czasie próbki mierzonego sygnału $y(n)$

D. Element $\hat{p}$ jest wektorem znanych (prawdziwych) parametrów modelu obiektu

10. Jeżeli dynamikę systemu opisuje następujące równanie $y(n) + ay(n-1) = bu(n-1) + e(n)$ gdzie $e(n)$ jest szumem białym wówczas: (B, C)

A. Dynamikę toru sterowania w systemie definiuje wyrażenie $G(q) = \frac{1+aq^{-1}}{bq^{-1}}$

B. Wektor regresji przyjmuje postać $\varphi^T(n) = [-y(n-1) \quad u(n-1)]$

C. Dynamikę toru zakłócenia w systemie definiuje wyrażenie $H(q) = \frac{1}{1+aq^{-1}}$

D. Dynamikę toru zakłócenia w systemie definiuje wyrażenie $H(q)=1$

11. Jeżeli dynamikę systemu opisuje następujące równanie

$A(q^{-1})y(n) = B(q^{-1})u(n) + C(q^{-1})e(n)$ gdzie $e(n)$ jest szumem białym wówczas: (A, C)

A. Model powyższy określany jest mianem modelu ARMAX

B. Model powyższy określany jest mianem modelu ARMA

C. Postać wielomianu $C(q^{-1})$ dedykuje o kolorze szumu $C(q^{-1})e(n)$

D. Wielomian $B(q^{-1})$ jest wielomianem monicznym

12. Metoda identyfikacji RLS (B, D)

A. Wynika z równania $\hat{p}(n) = \hat{p}(n-1) + k\varepsilon(n)$ gdzie $k=\text{const}$

B. Daje estymatory obciążone gdy szum działający na system jest szumem kolorowym

C. Pozwala na śledzenie zmiennych w czasie parametrów systemu gdy współczynnik zapomina $\lambda = 1$

D. Pozwala na śledzenie zmiennych w czasie parametrów systemu gdy współczynnik zapomina $\lambda \in (0, 1)$

13. Metoda identyfikacji RELS (A, C)

- A. Pozwala na estymację parametrów wielomianu $C(q^{-1})$ modelu ARMAX
- B. Daje taką samą jakość estymacji jak metoda RLS gdy szum biały działający na system jest kolorowy
- C. Wymaga uwzględnienia opóźnionych próbek błędu predykcji $\varepsilon(n)$ w wektorze regresji
- D. Może być stosowana tylko do modelu ARX

14. metoda identyfikacji RELS (A, C)

- A. pozwala na estymację parametrów wielomianu $C(q^{-1})$ modelu ARMAX
- B. jest zalecana w przypadku, gdy błąd równaniowy jest szumem białym
- C. wykorzystują opóźnienie próbki błędu predykcji jednokrokowej w wektorze regresji
- D. jest dedykowana dla modelu ARX

15. Filtracja Kalmana (C, D)

- A. Może być zawsze utożsamiana z estymacją RLS
- B. Pozwala na estymację struktury modelu systemu dynamicznego w oparciu o pomiar wyjścia w obecności zakłóceń stochastycznych
- C. Pozwala na estymację stanu systemu dynamicznego w oparciu o pomiar wyjścia w obecności zakłóceń stochastycznych
- D. Składa się z dwóch etapów: predykcji (estymacji a priori) oraz korekcji (estymacji a posteriori)

16. Algorytmy sterowania adaptacyjnego (B, C)

- A. Zawsze dają lepszą jakość regulacji w porównaniu z algorytmami klasycznymi (PID itp.)
- B. Charakteryzują się występowaniem dwóch pętli: sprzężenia zwrotnego oraz pętli adaptacji
- C. Cechuje zdolność do przestrajania parametrów regulatora
- D. Wymagają uprzedniej wsadowej identyfikacji obiektu sterowania

17. Zastosowanie adaptacyjnego schematu sterowania jest uzasadnione gdy: (B, C)

- A. Dynamika obiektu regulacji jest nieliniowa i wykazuje własności niestabilności
- B. Dynamika obiektu regulacji jest złożona i nieznaną
- C. Dynamika obiektu regulacji jest zmienna w czasie a zmiany te nieprzewidywalne
- D. Dynamika obiektu regulacji jest znana i niezmienna

18. Schemat sterowania typu Gain Scheduling (B, C)

- A. Automatycznie i na bieżąco (on-line) tworzy tablice szeregująca zbiory parametrów regulatora
- B. Wymaga wyboru tzw. Zmiennych wiodących (segregujących)
- C. Jest często stosowany między innymi w systemach sterowania lotem
- D. Wymaga realizacji bloku rekurencyjnej identyfikacji obiektu sterowania

19. W schemacie sterowania typu MRAS/MRAC (B, D)

- A. Prawo adaptacji jest funkcją bloku identyfikacji obiektu sterowania
- B. Prawo przestrajania parametrów regulatora z reguła MIT ma charakter gradientowy
- C. Model referencyjny określa pożądaną dynamikę obiektu sterowania
- D. Model referencyjny określa pożądaną dynamikę zamkniętego układu regulacji

20. W układzie sterowania MRAS z regulatorem MIT (A, C)

- $\dot{p} = -\gamma \frac{\partial J(\varepsilon)}{\partial p}$ gdzie $J(\varepsilon)$ jest funkcją kosztu
- A. Zmiana parametrów regulatora wynika z równania
- B. Mamy gwarancję zbieżności parametrów p regulatora do wartości nominalnych p_0
- C. Praktyczna realizacja prawa adaptacji zwykle wymaga poczynienia stosownych aproksymacji
- D. Szybkość zbieżności parametrów regulatora p zależy od wartości współczynnika γ i nie zależy od własności sygnału referencyjnego (zadanego)

21. Prawo adaptacji w schemacie sterowania MRAC (A, D)

- A. Może zostać wyprowadzone w oparciu o II metodę Lapunowa z gwarancją globalnych zbieżności błędu nadeżwania za modelem $\varepsilon = y_m - y$
- B. Pozwala zakwalifikować sterowanie MRAC do grupy pośrednich algorytmów adaptacyjnych
- C. Gwarantuje zerowanie błędu $\varepsilon = y_m - y$ tylko w przypadku gdy parametry regulatora zbiegają do wartości nominalnych p_0
- D. Jest niewrażliwe na amplitudę sygnału referencyjnego (zadanego) po zastosowaniu
- $\dot{p} = -\gamma \varepsilon \frac{\varphi}{\alpha + \varphi^T \varphi}$ gdzie $\alpha > 0, \varphi = \frac{\partial \varepsilon}{\partial p}$
- procedury normalizacji

22. Regulator RST (B, C)

- A. Jest tożsamy z regulatorem STR
- B. Jest zwany regulatorem (sterownikiem) o dwóch stopniach swobody
- C. W dyskretniej dziedzinie czasu jest opisany równaniem:
- $$u(n) = -\frac{S(q^{-1})}{R(q^{-1})} y(n) + \frac{T(q^{-1})}{R(q^{-1})} y_r(n)$$
- D. Jest nie przyczynowym obiektem dynamicznym gdy $\deg R > \deg S$

23. Sterowanie adaptacyjne w schemacie STR (C, D)

- A. Automatycznie zapewnia synteza strukturalna regulatora
- B. Zwane jest także sterowaniem typu Auto-tuning
- C. Wymaga identyfikacji obiektu sterowania w trybie na bieżąco (on-line)
- D. Można zakwalifikować do grupy pośrednich algorytmów adaptacyjnych

24. W schemacie sterowania typu Self-tuning (C, D)

- A. Struktura regulatora RST dopuszcza skracanie zer obiektu nieminimalnofazowego
- B. Jakość sterowania określa się w oparciu o jakość bieżącej identyfikacji obiektu sterowania
- C. Synteza parametryczna regulatora jest wykonywana na bieżąco z okresem T_d
- D. Przed doбором struktury regulatora należy wybrać kryterium syntezy układu regulacji

25. Procedura określana mianem Auto-tuningu (A, C)

- A. Pozwala wykorzystywać wszystkie znane techniki adaptacyjne w etapie automatycznego doboru nastaw regulatora
- B. Należy do rzadko stosowanych w praktyce schematów adaptacyjnych
- C. Składa się z dwóch etapów: automatycznego doboru nastaw regulatora i następującej po tym pracy układu regulacji ze stałymi nastawami
- D. Zwykle polega na cyklicznym doborze nastaw regulatora w oparciu o bieżące estymaty parametrów modelu obiektu regulacji

26. Model systemu rzeczywistego (B, D)

- A. jest wykorzystywany głównie w obszarze nauki i techniki
- B. może mieć moc wyjaśniającą naturę modelowanego procesu
- C. zawsze jest wyrażany w języku matematyki w postaci stosownego równania
- D. jest przybliżonym opisem systemu wynikającym z poczynionych założeń upraszczających

27. Model eksperymentalny (A, B)

- A. w warunkach praktycznych zawsze jest obciążony niepewnością modelowania
- B. nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori
- C. nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu jest znana a priori
- D. nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori

28. Model eksperymentalny (B, D)

- A. ma zwykle podobną moc wyjaśniającą jak model analityczny
- B. nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori
- C. nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori
- D. nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu nie jest znana a priori

29. Procedura identyfikacji parametrycznej (B, C)

- A. może być w prosty sposób zautomatyzowany (nie wymaga ingerencji projektowania modelu)
- B. ma charakter iteracyjny, podobnie jak każdy proces projektowy
- C. wykorzystuje dostępną wiedzę wstępną o identyfikowanym systemie
- D. ogranicza się do wyznaczenia (estymacji) parametrów modelu

30. Analiza korelacyjna (A, C)

- A. należy do nieparametrycznych metod identyfikowanego systemu dynamicznego
- B. wymaga znalezienia parametrycznego modelu identyfikowanego systemu dynamicznego
- C. polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego
- D. polega na oszacowaniu funkcji korelacji wzajemnej sygnału wyjściowego y z sygnałem wejściowym u w systemie dynamicznego

31. Analiza korelacyjna obiektu opisanego równaniem $y(n) = \sum_{i=0}^{\infty} g_o(i)u(n-i) + v(n)$: (C, D)

- A. polega na oszacowaniu skończonej liczby punktów charakterystyki statycznej obiektu
- B. wymaga znalezienia parametrycznego modelu identyfikowanego systemu dynamicznego
- C. polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego
- D. wymaga nieskorelowania sygnału wejściowego $u(n)$ z zakłóceniem stochastycznym $v(n)$

32. Dane jest równanie modelu systemu $y^{(2)} + y^{(1)} + y^{p1} = p_2 u$, gdzie p_1 i p_2 są szukanymi parametrami modelu, y jest sygnałem wyjściowym, u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas (A, D)

26. Model systemu rzeczywistego (B, D)

- A. jest wykorzystywany głównie w obszarze nauki i techniki
- B. może mieć moc wyjaśniającą naturę modelowanego procesu
- C. zawsze jest wyrażany w języku matematyki w postaci stosownego równania
- D. jest przybliżonym opisem systemu wynikającym z poczynionych założeń upraszczających

27. Model eksperymentalny (A, B)

- A. w warunkach praktycznych zawsze jest obciążony niepewnością modelowania
- B. nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori
- C. nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu jest znana a priori
- D. nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori

28. Model eksperymentalny (B, D)

- A. ma zwykle podobną moc wyjaśniającą jak model analityczny
- B. nazywany jest modelem typu GREY-BOX, jeżeli struktura modelu jest znana a priori
- C. nazywany jest modelem typu GREY-BOX, jeżeli parametry modelu są znane a priori
- D. nazywany jest modelem typu BLACK-BOX, jeżeli struktura modelu nie jest znana a priori

29. Procedura identyfikacji parametrycznej (B, C)

- A. może być w prosty sposób zautomatyzowany (nie wymaga ingerencji projektowania modelu)
- B. ma charakter iteracyjny, podobnie jak każdy proces projektowy
- C. wykorzystuje dostępną wiedzę wstępną o identyfikowanym systemie
- D. ogranicza się do wyznaczenia (estymacji) parametrów modelu

30. Analiza korelacyjna (A, C)

- A. należy do nieparametrycznych metod identyfikowanego systemu dynamicznego
- B. wymaga znalezienia parametrycznego modelu identyfikowanego systemu dynamicznego
- C. polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego
- D. polega na oszacowaniu funkcji korelacji wzajemnej sygnału wyjściowego y z sygnałem wejściowym u w systemie dynamicznego

31. Analiza korelacyjna obiektu opisanego równaniem (C, D)

- A. polega na oszacowaniu skończonej liczby punktów charakterystyki statycznej obiektu
- B. wymaga znalezienia parametrycznego modelu identyfikowanego systemu dynamicznego
- C. polega na oszacowaniu skończonej liczby próbek odpowiedzi impulsowej systemu dynamicznego
- D. wymaga nieskorelowania sygnału wejściowego $u(n)$ z zakłóceniem stochastycznym $v(n)$

32. Dane jest równanie modelu systemu $y^{(2)} + y^{(1)} + y^{p1} = p_2 u$, gdzie p_1 i p_2 są szukanymi parametrami modelu, y jest sygnałem wyjściowym, u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas (A, D)

A. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zmiany zmiennych $y^* := \ln y$ i $u^* := \ln u$

B. identyfikacja modelu charakterystyki statycznej systemu wymaga opracowania sygnałów $y^{(2)}$ i $y^{(1)}$

C. model odwzorowania wejścia sterującego w wyjście w stanie ustalonym ma postać $y^{p1} = p_2 u$

D. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zmiany zmiennych $y^* := y^{p1}$ i $u^* := u$

33. Dane jest równanie modelu systemu $y^{(2)} + p_4 y^{(1)} + p_3 y^{p1} = p_2 u$, gdzie p_i dla $i=1, \dots, 4$ są parametrami modelu, y jest sygnałem wyjściowym, u jest sygnałem sterującym (wejściowym), przy czym oba sygnały y i u są dostępne pomiarowo. Wówczas (probably A)

A. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zmiany zmiennych $y^* := \log y$ i $u^* := \log u$

B. model regresyjny odwzorowania wejścia u we wyjście y w stanie ustalonym ma 2 niezależne parametry

C. identyfikacja modelu charakterystyki statycznej systemu wymaga znajomości sygnałów $y^{(2)}$ i $y^{(1)}$

D. charakterystykę statyczną systemu można zidentyfikować zapisując jej model w postaci regresji liniowej $y^* = \varphi^T p$ po zastosowaniu zmiany zmiennych $y^* := y^{p1}$ i $u^* := u$

34. Zwiększenie liczby niezależnych parametrów w modelu (A, C)

A. powinno być dobrze uzasadnione zgodnie z zasadą oszczędności modelu

B. ułatwia przygotowanie i realizację eksperymentu identyfikacyjnego

C. może prowadzić do zjawiska nadparametryzacji modelu i w konsekwencji do niskiej jakości estymacji parametrycznej

D. Zwiększa elastyczność modelu i w tym samym zawsze skutkuje poprawą jakości wyznaczonego modelu

35. Zwiększanie liczby niezależnych parametrów p w modelu parametrycznym $M(p)$ (A, C)

A. powinno być ograniczone zgodnie z zasadą oszczędności modelu

B. ułatwia przygotowanie i realizację eksperymentu identyfikacyjnego

C. może prowadzić do nadparametryzacji modelu i w konsekwencji do wzrostu wariancji estymatora

D. zwiększa elastyczność modelu i w tym samym zawsze skutkuje poprawą jakości wyznaczonego modelu

36. Współczynnik szczytu C_r sygnału pobudzającego $u(n)$ (C, D)

A. zaleca się, aby był jak największy podczas eksperymentu identyfikacyjnego

B. ma wartość $C_r = 0.5$, gdy $u(n)$ jest sygnałem typu suma sinusów

C. ma wartość $C_r = 1$, gdy $u(n)$ jest sygnałem typu PRBS

D. zaleca się, aby był jak najmniejszy podczas eksperymentu identyfikacyjnego

37. Współczynnik szczytu C_r sygnału pobudzającego $u(n)$ (C, probably D)

A. zaleca się, aby był jak największy podczas eksperymentu identyfikacyjnego

B. ma wartość $C_r = 0.5$, gdy $u(n)$ jest sygnałem typu suma sinusów o fazach Schroedera

C. ma wartość $C_r = 1$, gdy $u(n)$ jest sygnałem typu PRBS

D. zaleca się, aby był bliski jedności podczas eksperymentu identyfikacyjnego

38. identyfikacja obiektu objętego ujemnym sprzężeniem zwrotnym w układzie regulacji z konwencjonalnym liniowym regulatorem o stałych parametrach (C, D)

A. jest zalecana ze względu na gwarancję nieustannego pobudzenia systemu sygnałem sterującym

B. zwykle daje lepsze wyniki niż identyfikacja w układzie otwartym

C. może prowadzić do jednoznacznej estymacji parametrów modelu ze względu na zależność sygnału wejściowego obiektu od jego odpowiedzi

D. może być konieczna aby zapewnić ograniczoną odpowiedź identyfikowanego obiektu

39. niech $y_m(n)$, $\hat{y}(n|n-1)$, $y(n)$ oraz $y_o(n)$ oznaczają odpowiednio odpowiedź modelu symulowanego, odpowiedź predyktora jedno-krokowego, zmierzoną odpowiedź rzeczywistego systemu oraz odpowiedź rzeczywistego systemu bez zakłócenia. Weryfikacja krzyżowa uzyskanego modelu czasu dyskretnego w warunkach praktycznych (probably B, D)

A. jest najbardziej miarodajna, jeżeli wynika z porównania odpowiedzi $\hat{y}(n|n-1)$ z $y_o(n)$

B. nie zawsze jest miarodajna, jeżeli wynika z porównania odpowiedzi $\hat{y}(n|n-1)$ z $y(n)$

C. może polegać na porównaniu odpowiedzi $y_m(n)$ z $y_o(n)$

D. nie jest zawsze miarodajna, jeżeli wynika z porównania odpowiedzi $y_m(n)$ z $y(n)$

40. Niech $y_m(n)$, $\hat{y}(n|n-1)$, $y(n)$ oraz $y_o(n)$ oznaczają odpowiednio odpowiedź modelu symulowanego, odpowiedź predyktora jedno-krokowego, zmierzoną odpowiedź rzeczywistego systemu oraz odpowiedź rzeczywistego systemu bez zakłócenia. Weryfikacja krzyżowa uzyskanego modelu w warunkach praktycznych (A, D)

A. może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y(n)$

B. może polegać na porównaniu odpowiedzi $\hat{y}(n|n-1)$ z $y_o(n)$

C. może polegać na porównaniu odpowiedzi $y_m(n)$ z $y_o(n)$

D. może polegać na porównaniu odpowiedzi $y_m(n)$ z $y(n)$

41. weryfikacja wyznaczonego modelu parametrycznego (B, C)

A. w praktyce polega na porównaniu obliczonych estymat $\hat{p}_N$ z prawdziwymi parametrami p_o systemu

B. dotyczy elastyczności, oszczędności i użyteczności modelu w danym zastosowaniu

C. powinna sugerować wybór najoszczędniejszego modelu spośród wszystkich akceptowanych modeli

D. powinna być wykonywana z wykorzystaniem danych użytych do estymacji parametrów modelu

42. Praktyczna weryfikacja wyznaczonego użytkowego modelu parametrycznego $M(\hat{p})$ (A, D)

- A. polega na sprawdzeniu jego użyteczności w danym zastosowaniu
- B. polega na porównaniu obliczonych estymat $\hat{p}_N$ z prawdziwymi parametrami p_o systemu prawdziwego
- C. powinna być wykonywana z wykorzystaniem tych samych danych, które użyto do estymacji parametrów modelu
- D. w podejściu BLACK-BOX powinna sugerować wybór najoszczędniejszego modelu spośród wszystkich akceptowanych modeli alternatywnych

43. wybór okresu próbkowania $T_p > 0$ sygnałów $u(t)$ oraz $y(t)$ do celów parametrycznej identyfikacji modelu czasu dyskretnego (A, D)

- A. jest właściwy jeżeli $T_p \approx T/10$ gdzie $T > 0$ jest dominującą stałą czasową systemu czasu ciągłego
- B. generalnie jest tym lepszy i mniejsza wartość T_p
- C. nie ma wpływu na jakość identyfikację, gdy tylko spełnia twierdzenie o próbkowaniu
- D. sugeruje mniejsze wartości T_p , gdy model ma być lepiej dopasowany w zakresie wyższych częstotliwości

44. rząd δ_u nieustannego pobudzenia sygnału $u(n)$ stosowanego podczas eksperymentu identyfikacyjnego (B, C)

- A. nie ma wpływu na zbieżność estymat parametrów modelu przy identyfikacji modelu RIV
- B. jest związany z liczbą składowych częstotliwościowych zawartych w sygnale $u(n)$
- C. powinien być taki, że $\delta_u \geq \dim(p)$, gdzie p jest wektorem parametrów modelu toru sterowania
- D. jest równy 2, gdy ma on postać sumy dwóch składowych sinusoidalnych o różnych pulsacjach

45. rząd δ_u nieustannego pobudzenia sygnału $u(n)$ stosowanego podczas eksperymentu identyfikacyjnego (B, D)

- A. nie ma wpływu na zbieżność estymat parametrów modelu przy identyfikacji modelu RIV
- B. jest dowolnie duży, jeżeli $u(n)$ jest szumem białym
- C. jest równy 2, gdy ma on postać sumy dwóch składowych sinusoidalnych o różnych pulsacjach
- D. wynika z liczby składowych częstotliwościowych zawartych w sygnale $u(n)$

46. zebrano niezależnie dwa zbiory Z_1 i Z_2 próbek sygnału wejściowego i wyjściowego pewnego systemu. Przeprowadzono identyfikację parametru p modelu tego systemu niezależnie dla obu zbiorów danych uzyskując estymatory: $\hat{p}_1$ (na podstawie zbioru Z_1) oraz $\hat{p}_2$ (na podstawie zbioru Z_2). Obliczono wartości wariancji v_1 i v_2 dla poszczególnych estymat. Optymalną (w sensie minimum wariancji) wypadkową estymatę $\hat{p}$ parametru p oraz odpowiadające jej wartości wariancji v uzyskamy, gdy (A, D)

A. $\hat{p} = (v_2 \hat{p}_1 + v_1 \hat{p}_2) / (v_1 + v_2)$

B. $\hat{p} = (\hat{p}_1 + \hat{p}_2) / (v_1 + v_2)$

C. $v = (v_1 + v_2) / 2$

D. $v = v_1 v_2 / (v_1 + v_2)$

47. adaptacyjna identyfikacja zmiennych parametrów $p_o(n)$ systemu rzeczywistego metodą RLS z wykorzystaniem mechanizmu resetowania macierzy kowalencyjnej $P(n)$ (C, D)

A. polega na zerowaniu macierzy $P(n)$ w chwili wykrycia zmian parametrów systemu

B. jest zalecana w przypadku wolnozmiennych lecz ustawicznych zmian parametrów $p_o(n)$

C. może skutkować nagłą zmianą (udarem) estymat parametrów modelu zaraz po resecie macierzy $P(n)$

D. polega na podstawieniu pod $P(n)$ macierzy diagonalnej o nieujemnych elementach diagonalii

48. parametryczna identyfikacja systemu $y = \varphi^T p_o + v$ w układzie otwartym metodą zmiennych instrumentalnych (B, C)

A. zawsze daje lepsze wyniki estymacji parametrów niż te uzyskane metodą LS niezależnie od charakteru zakłócenia v

B. Pozwala na uzyskanie zgodnych estymat parametrów nawet, gdy zakłócenie v jest kolorowe

C. wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z zakłóceniem v

D. wymaga zdefiniowania zmiennych instrumentalnych nieskorelowanych z elementami wektora φ

49. rekursywna metoda najmniejszych kwadratów wyznaczająca estymatę $\hat{p}(n)$ (B, C)

A. wynika z równania aktualizacji $\hat{p}(n) = \hat{p}(n-1) + k\varepsilon(n)$, gdzie $k = \text{const}$

B. w wersji podstawowej skutkuje stopniową utratą zdolności adaptacyjnych estymatora gdy $n \rightarrow \infty$

C. w wersji RLS_λ po zastosowaniu współczynnika zapominania $\lambda \in (0; 1)$ pozwala na śledzenie wolno-zmiennych parametrów $p_o(n)$ systemu rzeczywistego

D. musi być wykonywana w trybie on-line, tj. w czasie rzeczywistym i równoległe do działającego systemu rzeczywistego

50. rekursywna metoda najmniejszych kwadratów błędów równaniowych służąca wyznaczaniu $\hat{p}(n)$ (A, C)

- A. w wersji podstawowej skutkuje stopniową utratą zdolności adaptacyjnych estymatora gdy $n \rightarrow \infty$
- B. wynika z równania aktualizacji $\hat{p}(n) = \hat{p}(n-1) + k\varepsilon(n)$, gdzie k jest stałym wzmocnieniem
- C. po zastosowaniu współczynnika zapominania $\lambda \in (0; 1)$ pozwala na śledzenie wolnozmiennych parametrów $p_o(n)$ systemu rzeczywistego
- D. musi być wykonywana w trybie on-line, tj. w czasie rzeczywistym i równoległe do działającego systemu rzeczywistego

51. System generujący dane pomiarowe ma postać $y^{(2)}(t) + p_{10}y^{(1)}(t) = p_{20}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $y(t)$ oraz $u(t)$ wówczas model wyjaśniający dane pomiarowe spróbowane z okresem $T_p > 0$ (C, D)

- A. postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p) \quad u(nT_p)]p + v(nT_p)$ nie jest użyteczny w praktyce
- B. postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p) \quad u(nT_p)]p + v(nT_p)$ zachowuje strukturę systemu czasu ciągłego
- C. postaci $y^{(2)}(nT_p) = [-y^{(1)}(nT_p) \quad u(nT_p)]p + v(nT_p)$ jest modelem czasu dyskretnego
- D. wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachował strukturę systemu czasu ciągłego

52. System generujący dane pomiarowe ma postać $y^{(2)}(t) + p_{10}y^{(1)}(t) + p_{30}y(t) = p_{20}u(t) + v(t)$, gdzie t oznacza czas ciągły, natomiast $v(t)$ jest zakłóceniem stochastycznym. Jeżeli pomiarowo dostępne są tylko sygnały $y(t)$ oraz $u(t)$ wówczas model

$y^{(2)}(nT_p) = [-p_{10}y^{(1)}(nT_p) - p_{30}y(nT_p) + p_{20}u(nT_p) + v(nT_p)]p$, $p = [p_1 \ p_2 \ p_3]^T$

wyjaśniający dane pomiarowe próbkowane z okresem $T_p > 0$: (probably A, C)

- A. jest modelem czasu dyskretnego
- B. zachowuje oryginalną strukturę systemu czasu ciągłego
- C. wymaga zastosowania filtrów SVF, jeżeli chcemy, aby zachowywał strukturę systemu czasu ciągłego
- D. wymaga zastosowania filtrów SVF, jeżeli ma być użyty do estymacji metodą LS parametrów p

53. system generujący dane pomiarowe ma postać $y(n) = [y(n-1) \ y(n-2) \ u(n-2)]p_o + e(n)$ gdzie p_o jest wektorem parametrów prawdziwych, $e(n)$ jest szumem białym. Jeżeli symbolem $\hat{p}$ oznaczamy estymatę wektora parametrów modelu tego systemu, wówczas (A, C)

- A. odpowiedź optymalnego predyktora ma postać $\hat{y}(n|n-1) = [y(n-1) \ y(n-2) \ u(n-2)]\hat{p}$
 B. odpowiedź optymalnego predyktora ma postać $\hat{y}(n|n-1) = [y(n-1) \ y(n-2) \ u(n-2)]p_o$
 C. Odpowiedź modelu symulowanego ma postać $y_m(n) = [y_m(n-1) \ y_m(n-2) \ u(n-2)]\hat{p}$
 D. Odpowiedź modelu symulowanego ma postać $y_m(n) = [y(n-1) \ y(n-2) \ u(n-2)]\hat{p}$

54. system generujący dane pomiarowe ma postać

$$y(n) = \frac{p_{20}q^{-2}}{1-p_{10}q^{-1}}u(n) + \frac{1}{1-p_{10}q^{-1}}e(n), \text{ gdzie } p_o = [p_{10} \ p_{20}]^T$$

jest wektorem parametrów prawdziwych, $e(n)$ jest szumem białym. Jeżeli symbolem $\hat{p}$ oznaczamy estymatę wektora parametrów modelu tego systemu, wówczas odpowiedź (Probably A, probably D)

- A. optymalnego predyktora jedno-krokowego ma postać $\hat{y}(n|n-1) = [y(n-1) \ y(n-2) \ u(n-2)]\hat{p}$
 B. optymalnego predyktora jedno-krokowego ma postać $\hat{y}(n|n-1) = [\hat{y}(n-1|n-2) \ u(n-2)]\hat{p}$
 C. modelu symulowanego ma postać $y_m(n) = [y(n-1) \ u(n-2)]\hat{p}$
 D. modelu symulowanego ma postać $y_m(n) = [y_m(n-1) \ u(n-2)]\hat{p}$

55. jeżeli model systemu opisano równaniem $y(n) + ay(n-1) = -bu(n-3) + C(q^{-1})e(n)$, gdzie $e(n)$ jest szumem białym, a $C(q^{-1})$ jest wielomianem operatora q^{-1} , wówczas (B, C)

- A. powyższy model należy do modeli typu ARMAX, jeżeli $C(q^{-1}) \equiv 1$
 B. Przy zapisie regresyjnym dla $C(q^{-1}) \equiv 1$ wektor regresji ma postać $\varphi = [-y(n-1) \ -u(n-3)]^T$
 C. dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny $H(q^{-1}) = \frac{C(q^{-1})}{1+aq^{-1}}$
 D. dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny $H(q^{-1}) = \frac{-bq^{-3}}{1+aq^{-1}}$


56. jeżeli model systemu opisano równaniem $y(n) + ay(n-1) = -bu(n-3) + ce(n-1) + e(n)$, gdzie $e(n)$ jest szumem białym, wówczas (probably B)

A. powyższy model należy do modeli typu ARX, jeżeli $c = 1$

B. Przy zapisie regresyjnym dla $c = 0$ wektor regresji ma postać $\varphi(n) = [-y(n-1) \ -u(n-3)]^T$

C. dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny $H(q^{-1}) = \frac{1+cq^{-1}}{1+aq^{-1}}$

D. dynamikę toru zakłócenia w systemie definiuje operator transmitancyjny $G(q^{-1}) = \frac{1-bq^{-3}}{1+aq^{-1}}$



Rysunek 1: (a) Odpowiedź skokowa pewnego liniowego systemu dynamicznego. (b) Wynik analizy widmowej pewnego systemu dynamicznego czasu ciągłego o transmitancji $G_o(s)$

57. Wykres na rysunku 1(a) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu liniowego przy czym skok pobudzenia o amplitudzie $A_u = 2$ podano w chwili $t=0$. Na podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że (A, D)

A. w transmitancji systemu występuje człon opóźniający e^{-sT_0} , w którym $T_0 > 3s$

B. wzmocnienie statyczne obiektu wynosi 0.5

C. transmitancja systemu posiada bieguny zespolone sprzężone

D. w transmitancji z systemu występuje zero w prawej półpłaszczyźnie zespolonej

58. Wykres na rysunku 1(a) przedstawia odpowiedź skokową pewnego asymptotycznie stabilnego systemu liniowego o transmitancji ściśle właściwej, przy czym skok pobudzenia o amplitudzie $A_u = 10$ podano w chwili $t=2s$. Na podstawie wykresu (stanowiącego wiedzę wstępną o systemie) można stwierdzić, że (B)

A. wzmocnienie statyczne obiektu wynosi 0.5

B. w transmitancji systemu występuje człon opóźniający e^{-sT_0} , w którym $T_0 > 3s$

C. transmitancja systemu posiada przynajmniej dwa bieguny rzeczywiste

D. w transmitancji systemu występuje dodatnie zero

59. rysunek 1(b) ilustruje wyniki analizy widmowej pewnego stabilnego i minimalnofazowego systemu $G_o(j\omega)$ uzyskany z wykorzystaniem dwóch estymatorów transmitancji:

$$\hat{G}_N^*(j\Omega_k) = \frac{Y_N(j\Omega_k)}{U_N(j\Omega_k)} \quad \text{oraz} \quad \hat{G}_N(j\Omega_k) = \frac{\hat{\Phi}_{yu}^s(j\Omega_k)}{\hat{\Phi}_{uu}^s(\Omega_k)}.$$

Na podstawie rysunku możemy wnioskować że (A, D)

- A. wariancja estymatora $\hat{G}_N^*(j\Omega_k)$ jest większa niż wariancja estymatora $\hat{G}_N(j\Omega_k)$
- B. transmitancja identyfikowanego systemu ma wyłącznie bieguny rzeczywiste
- C. pasmo przenoszenia identyfikowanego systemu wynosi $[0; \omega_c]$, gdzie $\omega_c < 1$ rad/s
- D. identyfikowany system posiada wzmocnienie statyczne $|k_o| \in [0; 1]$

60. rysunek 1(b) ilustruje wyniki analizy widmowej pewnego stabilnego i minimalnofazowego systemu o transmitancji widmowej $G_o(j\omega)$. Wyniki analizy uzyskano z wykorzystaniem dwóch estymatorów transmitancji:

$$\hat{G}_N^*(j\Omega_k) = \frac{Y_N(j\Omega_k)}{U_N(j\Omega_k)} \quad \text{oraz} \quad \hat{G}_N(j\Omega_k) = \frac{\hat{\Phi}_{yu}^s(j\Omega_k)}{\hat{\Phi}_{uu}^s(\Omega_k)}.$$

Na podstawie rysunku 1(b) możemy wnioskować, że (C)

- A. wynik $\hat{G}_N^*(j\Omega_k)$ uzyskano na podstawie danych zakłóconych losowo, natomiast wynik $\hat{G}_N(j\Omega_k)$ na podstawie danych bez zakłóceń
- B. transmitancja identyfikowanego systemu ma przynajmniej dwa bieguny zespolone sprzężone
- C. 3-dB pasmo przenoszenia identyfikowanego systemu wynosi $[0; \omega_c]$, gdzie $\omega_c > 1$ rad/s
- D. identyfikowany system posiada wzmocnienie statyczne $k_o < 0$

61. Dany jest model czasu dyskretnego (A, probably C)

$$y(n) = \frac{bq^{-2}}{1 + aq^{-1}}u(n) + \frac{1 + cq^{-1}}{1 + aq^{-1}}e(n),$$

gdzie $e(n)$ jest szumem białym, natomiast $a, b, c \neq 0$ są parametrami modelu, wówczas (A, probably C)

- A. model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2) \ e(n-1)]p + e(n)$, gdzie $p = [a \ b \ c]^T$
- B. model regresyjny ma postać $y(n) = [-y(n-1) \ u(n-2)]p + v(n)$, gdzie $p = [a \ b]^T$ oraz $v(n) = e(n) - ce(n-1)$
- C. model jest nie-przyczynowy ze względu na wejście u
- D. model jest typu ARX

62. estymator metody najmniejszych kwadratów błędów równaniowych (LS) (C, D)

- A. znajduje zastosowanie tylko dla modeli systemów liniowych
- B. wynika z minimalizacji kryterium $V_N \triangleq \frac{1}{2} \sum_{n=1}^N |y(n) - \hat{y}(n|n-1)|$
- C. przyjmuje jawną postać równania, gdy błąd równaniowy zależy liniowo od parametrów modelu
- D. może prowadzić do obciążonych estymat parametrów modelu

63. estymator metody najmniejszych kwadratów błędów równaniowych (LS) (C)

- A. znajduje zastosowanie tylko dla modeli systemów liniowych systemów statycznych
- B. wynika z minimalizacji kryterium $V_N \triangleq \frac{1}{2} \sum_{n=1}^N |y^2(n) - \hat{y}^2(n|n-1)|$
- C. przyjmuje jawną postać równania, gdy błąd równaniowy zależy liniowo od parametrów modelu

D. może być obciążony lub nieobciążony w zależności od charakteru zakłócenia występującego w równaniu regresji liniowej

64. Dany jest system rzeczywisty $y(n) = [y(n-1) u(n-2)]p_o + v(n)$ z którego zebrano dane pomiarowe $Z^N = \{y(n), u(n)\}_{n=0}^N$ i wyznaczono obciążone estymaty $\hat{p}^{LS} = [\hat{p}_1^{LS} \hat{p}_2^{LS}]^T$ modelu o tej samej strukturze wektora regresji. Stosując metodę identyfikacji typu RIV zmiennej instrumentalne (probably A, C)

A. można wybrać następująco $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [y(n-2) u(n-3)]\hat{p}^{LS}(n-1)$

B. można wybrać następująco $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [x(n-2) u(n-3)]\hat{p}^{LS}$

C. można wybrać następująco $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n) = [x(n-1) u(n-2)]\hat{p}^{LS}(n-1)$

D. można wybrać następująco $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n) = [y(n-1) u(n-2)]\hat{p}^{LS}$

65. Dany jest system rzeczywisty $y(n) = [y(n-1) u(n-2)]p_o + v(n)$ z którego zebrano dane pomiarowe $Z^N = \{y(n), u(n)\}_{n=0}^N$ i wyznaczono metodą LS obciążone estymaty $\hat{p}^{LS} = [\hat{p}_1^{LS} \hat{p}_2^{LS}]^T$ modelu o tej samej strukturze wektora regresji. Stosując metodę identyfikacji typu RIV wektor z zmiennych instrumentalnych dla modelu tego systemu można wybrać następująco: (probably A)


A. jako $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [y(n-2) u(n-3)]\hat{p}^{IV}(n-1)$

B. jako $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [x(n-2) u(n-3)]\hat{p}^{LS}$

C. jako $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [x(n-2) u(n-3)]\hat{p}^{IV}(n-2)$


D. jako $z \triangleq [x(n-1) u(n-2)]^T$, gdzie $x(n-1) = [u(n-2) u(n-3)]\hat{p}^{LS}$

66. Wykres na rysunku 2 przedstawia gęstość widmową mocy zaprojektowanego sygnału pobudzającego $u(n)$ typu GBN funkcji pulsacji unormowanej. Na podstawie wykresu można stwierdzić że (B, D)



- A. sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{ks}{1+sT}$, $T > 0$
 B. sygnał ten szczególnie nadaje się do identyfikacji parametrycznej modelu $G(s) = \frac{k}{1+sT}$, $T > 0$
 C. sygnał ten jest nieustannie pobudzający rzędu $\delta_u < 4$
 D. sygnał ten jest nieustannie pobudzający rzędu $\delta_u > 12$

67. Rysunek 2 przedstawia oszacowaną gęstość widmową mocy w funkcji pulsacji unormowanej dla zaprojektowanego sygnału pobudzającego $u(n)$ typu GBN. Na podstawie wykresu można stwierdzić że (xxx)



- A. sygnał ten szczególnie nadaje się do identyfikacji parametrycznej procesu $G_o(s) = \frac{k_o s}{1+sT_o}$, $T_o > 0$
 B. sygnał ten nadaje się do estymacji parametrów modelu ARX, w którym $n_a \leq 8$ i $n_b \leq 4$
 C. sygnał ten nieustannie pobudzający rzędu $\delta_u < 3$
 D. sygnał ten ma charakter binarnego szumu czerwonego

68. rzeczywisty system dynamiczny generujący dane pomiarowe ma postać $y = \varphi_o^T p_o + v$, gdzie φ_o oznacza prawdziwą strukturę wektora regresji, a p_o reprezentuje wektor prawdziwych parametrów systemu. Estymator LS zastosowany do modelu $y = \varphi^T p + v$ w celu parametrycznej identyfikacji systemu w układzie otwartym (A, C)

A. może posiadać własność zgodności, jeżeli dane pomiarowe zawierają wystarczająco bogatą informację o systemie

B. zawsze zwraca estymaty $\hat{p}_N$ równe p_o (z prawdopodobieństwem 1), gdy liczba danych $N \rightarrow \infty$

C. może mieć własności zgodności, jeżeli model wyjaśniający dane $y = \varphi^T p + v$ będzie taki, że $\varphi \equiv \varphi_o$ oraz v będzie szumem białym

D. będzie miał własności zgodności jeżeli tylko v będzie szumem białym

69. znana jest struktura identyfikowanego systemu dynamicznego:

$$y(n) = \frac{b_o q^{-1}}{1 + a_o q^{-1}} u(n) + \frac{1 + c_o q^{-1}}{1 + a_o q^{-1}} e(n), \quad (3)$$

przy czym $e(n)$ jest szumem białym, a $a_o, b_o \neq 0$ oraz c_o są nieznanymi parametrami prawdziwymi. Parametryczna identyfikacja systemu (3) w układzie otwartym metodą najmniejszych kwadratów błędów równaniowych (LS) (C, D)

A. może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli $c_o = a_o$

B. gwarantuje zgodną estymację parametrów $p = [a \ b]^T$ modelu, gdy tylko $u(n)$ jest szumem białym

C. asymptotycznie (tj. dla liczby danych $N \rightarrow \infty$) prowadzi do statystycznie równoważnych wyników estymacji niezależnie czy stosujemy wersję wsadową LS czy rekursywną RLS

D. może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli $c_o = 0$

70. Dana jest struktura identyfikowanego systemu dynamicznego generującego dane:

$$y(n) = \frac{b_o q^{-1}}{1 + a_o q^{-1}} u(n) + \frac{1 + c_o q^{-1}}{1 + a_o q^{-1}} e(n), \quad (2)$$

przy czym $e(n)$ jest szumem białym, a $a_o, b_o \neq 0$ oraz c_o są nieznanymi parametrami prawdziwymi. Parametryczna identyfikacja systemu (2) w układzie otwartym metodą najmniejszych kwadratów błędów równaniowych (LS) (B, D)

A. gwarantuje zgodną estymację parametrów $p = [a \ b]^T$ modelu, gdy tylko $u(n)$ jest szumem białym

B. może prowadzić do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli zachodzi $c_o = 0$

C. prowadzi do zgodnego estymatora parametrów $p = [a \ b]^T$ modelu, jeżeli zachodzi $c_o = a_o$

D. asymptotycznie (tj. dla liczby danych $N \rightarrow \infty$) prowadzi do statystycznie równoważnych wyników estymacji niezależnie czy stosujemy wersję wsadową LS czy rekursywną RLS

71. Dane jest równanie estymatora $\hat{p}_N = (\Phi^T \Phi)^{-1} \Phi^T y$, gdzie Φ jest stochastyczną macierzą regresji (tj. elementy macierzy Φ zależą od stochastycznego zakłócenia v obecnego w równaniu $y = \varphi^T p + v$), a $N \gg \dim(\hat{p}_N)$ jest liczbą par $\{u_n, y_n\}_{n=1}^N$ danych pomiarowych. Wówczas: (A, probably D)

- A. aby powyższy estymator był zgodny, zakłócenie stochastyczne v musi być szumem białym
- B. powyższy estymator gwarantuje zbieżność $\hat{p}_N$ do parametrów prawdziwych p_o jeżeli tylko $N \rightarrow \infty$
- C. aby powyższy estymator był zgodny z strukturą wektora regresji φ musi odpowiadać w strukturze prawdziwego wektora φ_o systemu (tj. systemu generującego dane)
- D. powyższy estymator jest nieobciążony, jeżeli wartość oczekiwana zakłócenia v w równaniu regresyjnym $y = \varphi^T p + v$ jest zerowa

72. Dane jest równanie estymatora $\hat{p}_N = (\Phi^T \Phi)^{-1} \Phi^T y$, gdzie Φ jest stochastyczną macierzą regresji (tj. elementy macierzy Φ nie są skorelowane ze stochastycznym zakłóceniem v z równania $y = \varphi^T p + v$), przy czym $N \gg \dim(\hat{p}_N) = \dim(p)$ jest liczbą par $\{u_n, y_n\}_{n=1}^N$ danych pomiarowych. Wówczas: (probably A, probably B)

- A. aby powyższy estymator był nieobciążony, wartość oczekiwana zakłócenia kolorowego v musi być zerowa
- B. aby powyższy estymator był nieobciążony, zakłócenie stochastyczne v musi być szumem białym
- C. macierz kowariancji estymatora $Cov[\hat{p}_N] = \sigma_v^2 (\Phi^T \Phi)^{-1}$ niezależnie od koloru zakłócenia v
- D. aby powyższy estymator był nieobciążony, macierz Φ musi być pełnego rzędu równego $\dim(p)$

73. Dany jest model systemu $a(t)\ddot{y}(t) + b\dot{y}(t) + c\sin(y) = ku^3(t)$, gdzie $k, b, c > 0$ są stałymi parametrami, natomiast $a(t) = A\sin(t)$ jest parametrem zmiennym w czasie. Wówczas można powiedzieć że: (B)

- A. model opisuje system stochastyczny
- B. model opisuje system niestacjonarny
- C. charakterystyka statyczna systemu przechodzi przez punkt $(u, y) = (0, 0)$
- D. w tak przyjętym opisie systemu nie jest istotny stan przejściowy odpowiedzi $y(t)$

74. Dane jest równanie estymatora $\hat{p}_N = (Z^T \Phi)^{-1} Z^T y$, gdzie Φ jest stochastyczną macierzą regresji (tj. elementy macierzy Φ są skorelowane ze stochastycznym zakłóceniem v z równania $y = \varphi^T p + v$), Z jest macierzą zmiennych instrumentalnych, natomiast $N \gg \dim(\hat{p}_N) = \dim(p)$ jest liczbą par $\{u_n, y_n\}_{n=1}^N$ danych pomiarowych. Wówczas: (probably B)

- A. powyższy estymator jest najefektywniejszy, jeżeli wartość oczekiwana zakłócenia $v(n)$ jest zerowa
- B. powyższy estymator może być zgodny tylko, jeżeli zakłócenie v jest białym szumem
- C. powyższy estymator może być zgodny, jeżeli elementy Z są skorelowane z elementami Φ
- D. powyższy estymator może być zgodny, jeżeli elementy Z nie są skorelowane z zakłóceniem v

75. dla systemu dynamicznego $y(n) = [-y(n-1) \ u(n-2)]p_o + v(n)$, gdzie $p_o = \text{const}$, uzyskano obciążenie estymaty $\hat{p}_N^{LS}$ parametrów. Aby zmniejszyć lub usunąć obciążenie można: (probably B, C)

- A. wyznaczyć wartości obciążenia i odjąć je od estymat w wektorze $\hat{p}_N^{LS}$
- B. zastosować estymację z użyciem dwuetapowej metody zmiennych instrumentalnych IV/LS
- C. zwiększyć stopnie wielomianów $A(q^{-1})$ i $B(q^{-1})$ modelu i zastosować ponownie metodę LS

D. zastosować metodę RLS z resetowaniem macierzy kowariancyjnej

76. filtracja filtrami analogowymi $F_u(s)$ i $F_y(s)$, odpowiednio, sygnałów $u(t)$ oraz $y(t)$ pochodzących z wejścia i wyjścia identyfikowanego procesu liniowego transmitancji $G_o(s, p_o)$ (maybe C, probably D)


A. nie ma wpływu na jakość identyfikacji parametrycznej, jeżeli tylko filtry $F_u(s) \equiv F_y(s)$ są jednakowe

B. jest zawsze konieczna w przypadku identyfikacji modelu czasu ciągłego

C. umożliwia dopasowanie modelu $G(j\omega, \hat{p})$ do wybranego zakresu częstotliwości

D. umożliwia zgodną identyfikację parametryczną modelu $G(s, \hat{p})$ o tej samej strukturze co $G_o(s, p_o)$ jeżeli filtry $F_u(s) \equiv F_y(s)$ są jednakowe

Dodatek A



Rysunek 4: Egzamin dyplomowy dla kierunku Automatyka i Robotyka – studia I stopnia, na konkurencyjnej polskiej uczelni technicznej.